目录

一、门控循环单元模型的由来及原理.....3

1.1 门控循环单元模型的由来.....3

1.2 门控循环单元模型的原理.....3

1.3 与 LSTM 模型对比.....5

1.4 门控循环单元模型的计算流程.....5

二、GRU 模型的应用.....6

2.1 数据由来.....6

2.2 数据预处理.....8

2.3 描述性统计.....10

2.4 GRU 模型的建立求解.....14

2.5 总结体会.....18

三、对本专业培养方案与课程制度的建议.....19

3.1 培养方案建议.....19

3.2 课程制度建议.....19

四、对过去三年的学习生活的体会.....20

五、未来规划.....21

六、参考文献.....21

一、门控循环单元模型的由来及原理

1.1 门控循环单元模型的由来

门控循环单元模型（GRU）由 CHO 等人于 2014 年提出，最早是在 RNN ENCODER-DECODER 框架下用于统计机器翻译。它要解决的是标准 RNN 的梯度消失的问题。普通 RNN 在反向传播时，状态转移矩阵连乘会随序列长度迅速衰减或爆炸，序列一长，模型就很难学到跨度较大的依赖关系。

GRU 借鉴了 LSTM 的门控思路，但结构上做了简化。LSTM 用输入门、遗忘门、输出门和独立的细胞状态控制信息流，2000 年 GERS 等人加入遗忘门后形成现在常见的三闸门结构。GRU 把输入门和遗忘门合并成更新门，同时去掉了独立的细胞状态，只保留隐藏状态。这样在相同隐藏维度下，GRU 的参数量比 LSTM 少，门控机制处理长程依赖的能力仍然保留。

CHUNG 等人在 2014 年做了系统的实证比较，多数序列建模任务上 GRU 的预测效果与 LSTM 相当，训练速度更快，参数效率也更高。此后 GRU 成为循环神经网络中常用的门控架构之一，在自然语言处理、语音识别和时间序列预测中都有应用。

后续研究围绕简化架构，比如去掉重置门的单门变体；替换激活函数等等进行展开，比如用 RELU 替代 TANH 来加快训练；以及硬件实现，比如基于忆阻器的 GRU 电路。

1.2 门控循环单元模型的原理

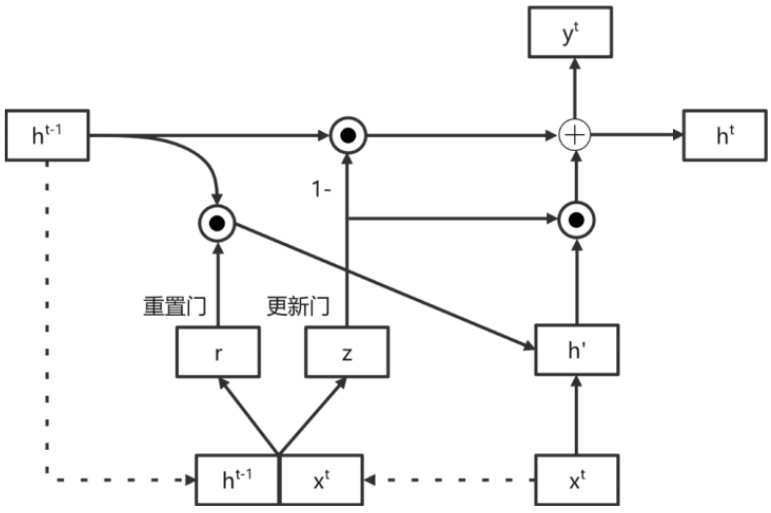


图 1 GRU 模型框架

门限循环单元，将输入和遗忘两个过程整合为一个新的过程，并将其与神经元活动相关联。GRU 网络体系中有两个门，其中，更新门与重置门用于决定已被删除的与被接收的数量，而刷新门则用于决定已被删除的或新被接收的的数量。直观上，LSTM 模型存在三个不同的门，参数较多，训练起来比较困难。GRU 仅包含两个门控机制，当所有超参量都被优化时，两者的表现相当，但是 GRU 具有更简单的架构和更小的训练样本，易于实现。GRU 架构具体如下：

为了更好的理解与比较，我们给出 LSTM 的模型结构图。

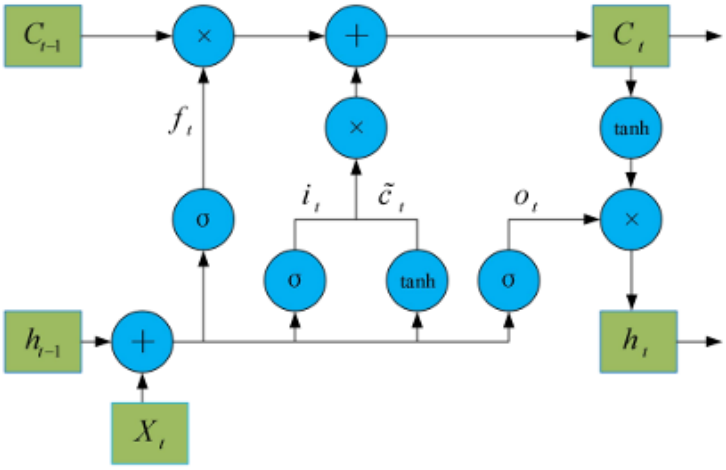


图 2 LSTM 模型框架

接下来，我们给定 GRU 模型的重置门和更新门的定义公式为：

$$r_t = \sigma\left(W_r[h_{t-1}, x_t] + b_r\right) \tag{1}$$

$$z_t = \sigma\left(W_z[h_{t-1}, x_t] + b_z\right) \tag{2}$$

其中，$\sigma(x) = \dfrac{1}{1+\mathrm{e}^{-x}}$，其中 h_{t-1} 包含了过去的信息，r 为重置门，当 r_t 趋近于零时，模型会将过去的隐藏信息丢弃，只留下当前输入的信息。当 r_t 趋近于 1 时，认为过去的信息都是有用的，并将其添加到当前信息中。

接下来我们给出候选隐藏层状态和最终隐藏状态的具体公式：

$$\tilde{h}_t = \tanh\left(W[r_t \odot h_{t-1}, x_t] + b\right) \tag{3}$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \tag{4}$$

其中，$\tilde{h}_t$ 主要包含了 t 时刻输入的 x_t 的信息和有针对性的对 $t-1$ 时刻的隐藏层状态 h_{t-1} 的保留。$(1-z_t)h_{t-1}$ 表示对原本隐藏状态的选择性以往，$z_t h_t$ 表示对当前节点的候选隐藏状态进行选择性记忆，同样也会忘记一些不重要的。当 z_t 趋近于 1 时，表示长期的依赖一直存在，当 z_t 趋近于 0 时，表示忘记隐藏信息中一些不重要的信息。

接下来，我们给出输出层概率计算的具体公式：

$$\hat{p} = \sigma(W_{\text{out}} h_t + b_{\text{out}}) \tag{5}$$

上述门控机制使 GRU 能够自适应地调节信息流动：当更新门接近 1 时，模型更倾向于保留历史信息；当更新门接近 0 时，模型更注重当前输入。重置门则控制模型对历史信息的利用程度。这种设计在简化 LSTM 结构的同时，依然能够有效捕捉时间序列中的长期依赖关系，且计算效率更高。

1.3 与 LSTM 模型对比

GRU 的参数优势主要来自两个方面：将输入门与遗忘门合并为一个更新门，减少了门控参数矩阵的数量；取消独立的细胞状态，减少了状态相关的计算和存储开销。需要指出的是，这种简化并非在所有任务上都占优；当任务需要显式分离长期记忆和短期输出时，LSTM 的独立细胞状态可能提供更细粒度的控制。选择 GRU 还是 LSTM，通常需要结合具体任务的数据规模、序列长度和计算预算进行验证。

表 1 模型对比

维度	LSTM	GRU
状态张量	隐藏状态 h_t 与细胞状态 C_t	仅隐藏状态 h_t
门数量	3 个（输入、遗忘、输出）	2 个（更新、重置）
参数规模	较多	比 LSTM 少
梯度缓解机制	细胞状态的加性更新	隐藏状态的加性凸组合更新
典型训练速度	较慢	较快

1.4 门控循环单元模型的计算流程

表 2 门控循环单元计算流程

门控循环单元模型的计算流程
原始时序序列 $X = \{x_1, x_2, \ldots, x_T\}$，窗口长度 τ，隐藏单元数 U，GRU 层数 L，批次大小 B，学习率 η，最大训练轮数 E，早停耐心值 P，
训练好的 GRU 模型参数 Θ，测试集预测结果 $\hat{Y}$
对 X 进行缺失值与异常值处理，得到清洗后的序列 $\tilde{X}$
对 $\tilde{X}$ 做 Min-Max 归一化，得到 X'
用长度为 τ 的滑动窗口切分 X'，构造输入—输出样本对集合 $\mathcal{D} = \{(X_i, Y_i)\}_{i=1}^{T-\tau}$
将 $\mathcal{D}$ 按比例划分为训练集 $\mathcal{D}_{\text{train}}$、验证集 $\mathcal{D}_{\text{val}}$ 和测试集 $\mathcal{D}_{\text{test}}$
初始化 GRU 网络参数 $\Theta = \{W_z, W_r, W_h, b_z, b_r, b_h, W_o, b_o\}$
初始化最优验证损失 $L_{\text{best}} \leftarrow +\infty$，早停计数 $c \leftarrow 0$

for epoch = 1 to E do

for 每个批次 $B \subset \mathcal{D}$ train do

初始化隐藏状态 $h_0 \leftarrow 0$

for{每个时间步 $t = 1$ to τ

$z_t \leftarrow \sigma(W_z \cdot [h_{t-1}, x_t] + b_z$

$r_t \leftarrow \sigma(W_r \cdot [h_{t-1}, x_t] + b_r$

$\tilde{h}_t \leftarrow \tanh\left(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h\right)$

$h_t \leftarrow (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}$

end for

取最后时间步隐藏状态 h_τ，计算预测值 $\hat{y} \leftarrow W_o h_\tau + b_o$

计算批次损失 $\mathcal{L} \leftarrow \frac{1}{|\mathcal{B}|} \sum_{(X_i, Y_i) \in \mathcal{B}} \ell(\hat{y}_i, Y_i)$，通过 BPTT 计算梯度 $\nabla_\Theta \mathcal{L}$

用 Adam 更新参数 $\Theta \leftarrow \Theta - \eta \cdot \mathrm{Adam}(\nabla_\Theta \mathcal{L})$

end for

在验证集 $\mathcal{D}_{\text{val}}$ 上计算验证损失 L_{val}

if $L_{\text{val}} < L_{\text{best}}$

$L_{\text{best}} \leftarrow L_{\text{val}}$,保存当前模型参数 $\Theta_{\text{best}} \leftarrow \Theta$， $c \leftarrow 0$

else

$c \leftarrow c + 1$

if $c \geq P$

break

end if

end if

End for

载入最优参数 $\Theta \leftarrow \Theta_{\text{best}}$

for{每个测试样本 $(X_i, Y_i) \in \mathcal{D}_{\text{test}}$

按前述前向计算得到预测值 $\hat{y}_i$，对 $\hat{y}_i$ 做反归一化，得到原始量纲下的预测值

end for

计算测试集 RMSE、MAE、MAPE 等指标

Return Θ， $\hat{Y}$

二、GRU 模型的应用

2.1 数据由来

我们所要研究的应用案例为基于信用卡消费行为的客户违约分析，在商业银行的各项业务中，银行卡业务所面临的信用风险问题尤为突出。该业务涉及发卡

行、持卡人、商户及受理机构等多方面，同时除了传统流动性及汇率风险外，信用风险所面临的挑战主要集中在消费信贷领域。主要表现特征为，严重的信息不对称性，银行难以准确掌握客户的真实财务状况与信用意愿，从而增加了隐瞒与欺诈的可能；个人客户的筹资能力相对薄弱，相较于企业，个人在金融市场上处于弱势，融资渠道有限，风险抵御能力不足；个人收入与支出的不确定性较高，收入来源往往单一，易受就业市场波动、意外事件或经济环境变化的影响，可能导致其偿债能力骤然下降，进而无法履行还款责任。面临着以上问题，如何构建好客户的违约信息预测模型是我们亟需解决的问题。

	SeriousDlc	RevolvingU	age	NumberOfTi	DebtRatio	MonthlyInc	NumberOfOp	NumberOfTi	NumberReal	NumberOfTi	NumberOfDependents
1	1	0.7661266	45	2	0.8029821	9120	13	0	6	0	2
2	0	0.957151	40	98	0.1218762	2600	4	0	0	0	1
3	0	0.6581801	38	96	0.0851134	3042	2	1	0	0	0
4	0	0.2338098	30	0	0.0360497	3300	5	0	0	0	0
5	0	0.9072394	49	1	0.0249257	63588	7	0	1	0	0
6	0	0.2131787	74	0	0.375607	3500	3	96	1	0	1
7	0	0.3056825	57	0	5710	NA	8	0	3	0	0
8	0	0.7544636	39	0	0.20994	3500	8	98	0	0	0
9	0	0.644226	30	0	0.3094762	2500	5	0	0	0	0
10	0	0.0187981	51	0	0.5315288	6501	7	0	2	0	2
11	0	0.0103519	46	0	0.2983541	12454	13	0	2	0	2
12	1	0.9646726	40	3	0.3829647	13700	9	3	1	1	2
13	0	0.0196566	76	0	477	0	6	0	1	0	0
14	0	0.5484581	64	0	0.2098918	11362	7	0	1	0	2
15	0	0.0610861	78	0	2058	NA	10	0	2	0	0
16	0	0.1662841	53	0	0.1882741	8800	7	0	0	0	0
17	0	0.2218128	43	0	0.5278878	3280	7	0	1	0	2
18	0	0.6027944	25	0	0.0658683	333	2	0	0	0	0
19	0	0.2009234	43	0	0.4300463	12300	10	0	2	0	0
20	1	0.0256557	38	0	0.4758414	3000	7	0	1	0	2
21	0	0.9999999	39	0	0.2411036	2500	4	0	0	0	0
22	0	0.0754266	32	0	0.0855122	7916	6	0	0	0	0
23	0	0.0465603	58	0	0.2416218	2416	9	0	1	0	0
24	1	0.3922485	50	0	1.5952534	4676	14	0	3	0	1
25	0	0.0524361	58	0	0.0976722	8333	22	0	1	0	0
26	0	0.0344215	69	0	0.042383	2500	17	0	0	96	1
27	0	0.4525158	24	0	0.0117612	3400	1	0	0	0	0
28	0	0.3929946	58	2	0.4361025	5500	15	0	1	0	0
29	0	0.704074	28	1	0.1552011	4200	8	0	0	98	0
30	0	0.9999999	24	0	0.4727031	750	1	0	0	0	0

图 3 原始数据表

我们所应用的数据集 cs-training.csv 共包含 980 位客户包括年龄、受抚养人数、过往违约次数等 11 个指标的相关信息，现要求我们对这些数据进行缺失值和异常值处理，确保数据在清洗过后能够直接用于违约分析模型的建立中；接下来要求我们建立一个基于 GRU 的客户违约预警模型能够有效辅助银行参与提供是否借贷的决策。

GRU 之所以能用来建立违约预警模型，关键在于违约预警本身不是一个静态分类问题，而是一个典型的带时间维度的风险预测问题：借款人或企业的违约风险不是某一时刻突然产生的，而是由历史还款行为、现金流变化、负债水平、交易记录、舆情和行业环境等序列信息逐步累积形成的。GRU 作为循环神经网络，正好擅长从这种按时间排列的多变量序列中提取依赖关系，因此可以作为违约预警模型的核心时序特征提取器。

2.2 数据预处理

对现有数据集进行分析，数据集中共给出了 980 位用户关于 11 个指标下的信息，我们首先对各指标进行分析与描述，具体如下表。

表 3 各指标含义

指标	中文含义
SeriousDlqin2yrs	2 年内严重逾期标识
RevolvingUtilizationOfUnsecuredLines	无担保信贷循环利用率
age	客户年龄
NumberOfTime30-59DaysPastDueNotWorse	2 年内逾期 30-59 天的次数
DebtRatio	债务比率
MonthlyIncome	月收入
NumberOfOpenCreditLinesAndLoans	当前信用账户总数
NumberOfTimes90DaysLate	2 年内逾期 90 天及以上的次数
NumberRealEstateLoansOrLines	房地产相关贷款/额度数量
NumberOfTime60-89DaysPastDueNotWorse	2 年内逾期 60-89 天的次数
NumberOfDependents	受抚养人数

通过该表的指标情况可知，过去两年内逾期 30-59 天逾期次数，这一次数最多为$365*2/30=24$次，因此在这一指标中过去逾期的次数超过 24 次的数据我们将其认定为脏数据，对含有以上数据的客户数据进行剔除；接着对于负债率大于 1 而月收入为 0 的数据我们不做处理，因为在现实生活中存在失业但从银行中贷款的真实案例存在，但对于负债率大于 1 但月收入为缺失值的数据我们予以剔除，由于月收入的缺失，数据表中负债率的计算值一定错误，因此这一数据值应当予以剔除；对于两年内逾期 90 天的次数超过 8 次的数据也予以剔除，在两年内能够最多逾期 8 次，多于 8 次的数据均为脏数据，不可代入；对于受抚养人数存在缺失值的情况，我们考虑到客户抚养人数一般与用户的年龄阶段直接相关，因此我们采用分层插值法对缺失的数据值予以补充，在年龄这一指标下，最小年龄为 22 岁，最大年龄为 92 岁，于是我们将年龄按照$[20,30]$，$[30,40]$，$[40.50]$，$[50,60]$,$[60,100]$这一分层年龄进行分层，用各层的受抚养人数的均值来填补缺失值，对于第k个年龄组$(k=1,2,\ldots,K)$，其抚养人数平均值计算公式为：

$$\bar{d}_k=\frac{\sum_{i=1}^{n_k}d_{ki}}{n_k} \tag{6}$$

其中，$\bar{d}_k$表示为第k个年龄组的抚养人数平均值，d_{ki}表示为第i个用户的实际抚

养权，n_k表示为第k组中抚养人数非缺失的用户数量。

接下来，通过 Python 对数据进行处理，剔除掉脏数据，并填补数据中的缺失值，通过处理最终得到有效数据样本 801 条，接下来我们引入箱型图来检查这指标中的数据是否存在异常值，箱线图进行异常值分析是基于四分位数和四分位距(IQR)来定义正常的数据范围，再此范围之外的数据点被识别为异常值，其中四分位距 IQR 的定义公式为：

$$IQR = Q3 - Q1 \tag{7}$$

其中，Q_3是上四分位数表示数据集中有 75%的数据小于此值，也就是箱型图的箱体上边界；Q_1是下四分位数表示数据集中有 25%的数据小于此值，也就是箱型图的箱体下边界。同时我们确定箱型图的正常值的取值范围为$[Q1-1.5*IQR, Q3+1.5*IQR]$，若数据不在这一范围内则说明该数据为异常值。接下来我们分别给出数据集中这 11 个指标的箱线图。

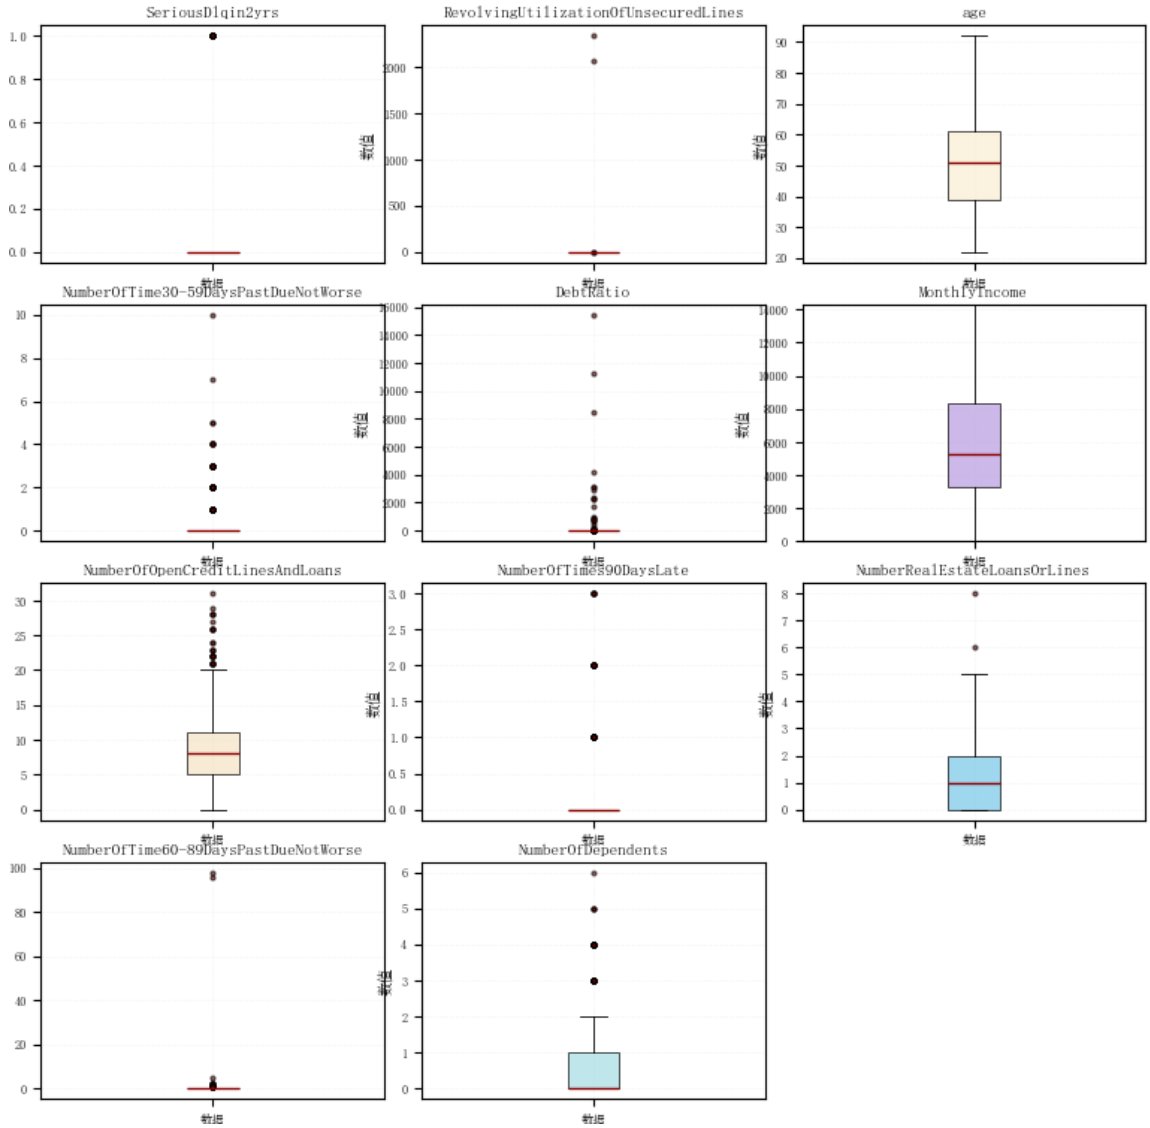


图 4 指标箱线图

通过上图可知，数据集中的客户年龄主要集中在 40-60 岁，月收入主要集中在 3000-10000 元，有固定存款平均每位用户均要承担抚养一位家庭成员的义务。上述数据集中但多数数据分布均匀但存在极个别异常值，在现实生活中通常也存在个别情况，因此这些符合现实情况的异常值我们予以保留。

2.3 描述性统计

接下来我们对数据集中所给的 801 条有效数据进行描述性统计，通过引入最大值，最小值，均值，方差，标准差，偏度系数，峰度系数这六个指标分别对 2 年内严重违约标识、无担保信贷循环利用率、客户年龄、月收入、受抚养人数等指标进行分析。

峰度系数衡量数据分布峰值的高低，如果峰度系数越接近 0，表示数据分布的峰态越接近正态分布；若峰度系数大于 0，表示分布为尖峰分布，数据更集中在均值附近；若峰度系数小于 0，表示分布为平峰分步，数据分布更平坦，尾部更薄，极端值较少。峰度系数的具体计算公式为：

$$K=\frac{\frac{1}{N}\sum_{i=1}^{N}(x_i-\mu)^4}{\left(\sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_i-\mu)^2}\right)^4}-3 \tag{8}$$

其中，μ 为总体均值，常数项-3 为修正项，确保正态分布的峰度为 0。

偏度系数是衡量数据分布不对称性的统计量，当数据分布对称时偏度系数等于 0，偏度系数值越低原始数据越接近对称分布，我们一般认为偏度系数大于或者是等于 1 或者是-1 时，数据严重偏斜分布；偏度系数的绝对值在 0.5-1 时，数据为中等偏斜分布；偏度系数的绝对值在 0-0.5 之间时，数据为轻微偏斜分布。当偏度系数为负值时数据呈现左偏分布，而为正值时数据呈现右偏分布。峰度系数的具体计算公式为：

$$SK=\frac{n}{(n-1)(n-2)}\sum\left(\frac{x_i-\bar{x}}{s}\right)^3 \tag{9}$$

接下来，我们给出这 11 个指标的描述性统计表。

表 4 描述性统计表

指标(简)	最大值	最小值	中位数	方差	峰度系数	偏度系数
SDl	1	0	0	0.0554	12.0836	3.7528
RUOUL	2340	0	0.17561	12161.45	401.144	20.0403
age	92	22	51	213.2285	-0.5564	0.2616
NOT30-59DL	10	0	0	0.6621	36.5284	4.8750
DebtRatio	15466	0	0.2970	629111.2	242.6903	14.6663
NOOCLAL	31	0	8	27.3509	1.3601	1.0271

NOT90DL	3	0	0	0.1454	29.1469	5.1893
NRELOL	8	0	1	1.0498	3.8802	1.3896
NOT60-89DP	98	0	0	23.5629	391.9191	19.8073
NOD	6	0	0	1.2347	1.4094	1.3793

通过该表，我们可以得到这些指标中 2 年内严重逾期标识指标中绝大多数样本都是 0，分布极度向右倾斜，表明在这一数据集中大多数客户为未违约的客户；无担保信贷循环利用率这一指标的最大值达 2340，可见客户中存在收入极小仅靠贷款来维持生机的人，同时债务比率最大值达到了 15466，波动非常剧烈，也说明了这一点；客户年龄则相对平稳，集中在 22 到 92 岁之间，中位数为 51 岁，分布较为均匀；这 11 个指标中大多数指标都呈现出“少数样本取值很大、多数样本取值很小或为零”的右偏分布规律，只有年龄等个别指标分布相对平衡。

接下来，我们对各指标进行横向对比分析，首先来研究各指标之间的相关性情况，由于数据集中的数据并不满足正态分布，我们引入 Spearman 相关性分析来确定这 11 个指标之间的相关性关系。Spearman 相关性分析是一种用于衡量两个变量之间的相关性强度的非参数方法,他不要求数据呈正态分布或者具有线性关系,能够处理连续但非正态分布的数据,一般来说计算得到的相关系数的绝对值越接近于 1,则两变量之间的相关程度越大，接下来我们给出 Spearman 相关系数 ρ 的计算公式:

$$\rho = 1 - \frac{6\sum_{i=1}^{n} d_i^2}{n(n^2-1)} \tag{10}$$

其中， n 表示样本量,$d_i = R(x_i) - R(y_i)$ 表示第 i 个观测在 X,Y 上的秩次之差。通过计算我们得到 Spearman 相关性热图，具体如下。

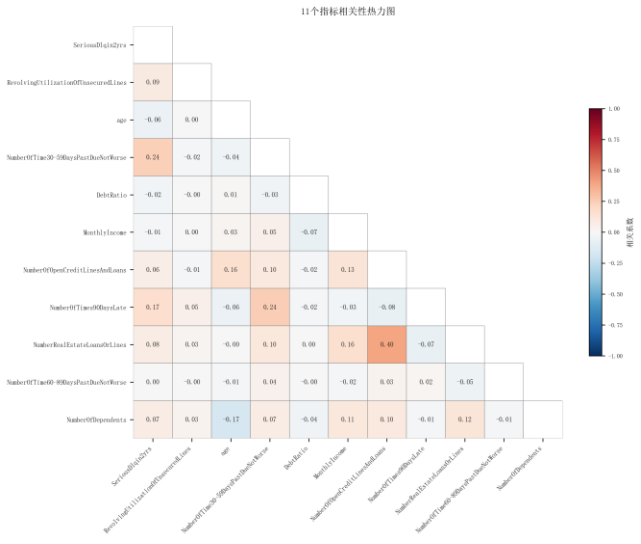


图 5 11 个指标的相关性热图

通过上图，我们可以发现各指标之间的相关性普遍较弱，房地产贷款度数与开放信用账户数的相关性指标为 0.4 呈弱正相关，逾期 90 天以上次数与逾期 30-59 天次数的相关性系数为 0.24，这表明短期逾期多则长期逾期可能也多。

接下来，我们来研究月收入，年龄，负债比，受抚养人数这几个指标的数据分布情况，我们给出这四个指标数据分布的核密度图，具体如下。

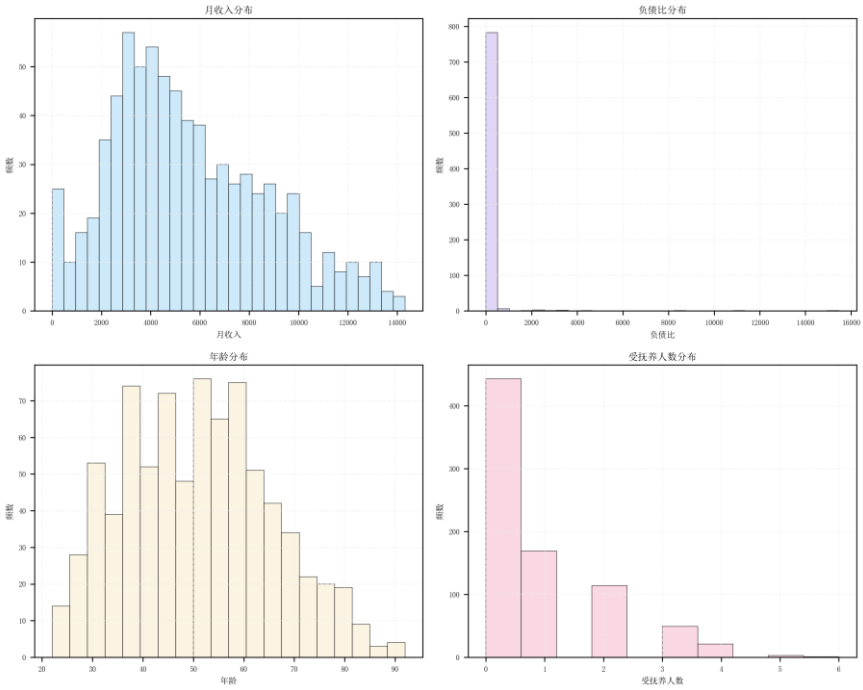


图 6 四个指标的核密度图

通过该图可以发现该数据集中客户月收入重要集中在$[2000,4000]$这一范围内，同时收入最高值和最低值之间相差 14000 元，相差数据较大，而对于负债比这一指标大多数人均是 0 负债只有少数人负债，该数据集中用户的年龄主要分布在$[35,55]$岁中间，这与现实生活中大多数为青壮年进行银行贷款的现实相符合，而受抚养人群中大多数人承担着抚养 1 位家属的责任但也有少数客户承担着抚养 2-3 位家属的责任。

接下来，我们给出不同年龄层中负债率、月收入与逾期率的组合图来进行横向对比，通过该图可以发现在数据集中$[40,50]$的年龄层中客户的月收入最高而平均负债比中等，$[70,100]$岁这一阶段的平均负债比最高。

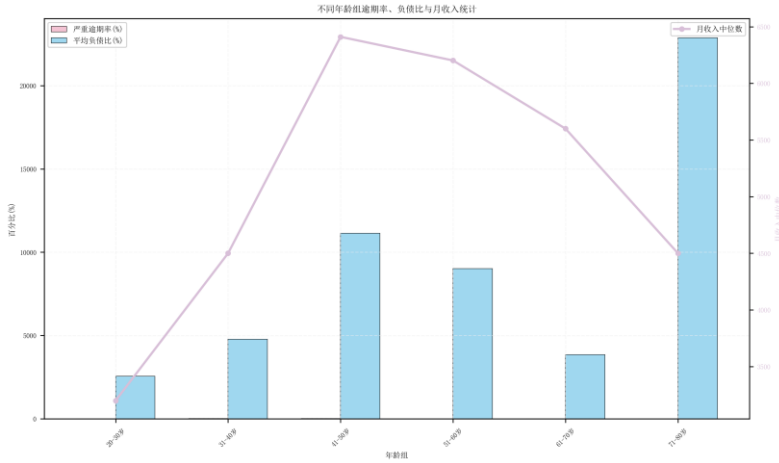


图 7 不同年龄组逾期率、负债比、月收入统计图

在数据预处理中我们得到在现有的有效数据中违约客户信息的数据仅占5.83%，而这样的数据集的学习效果欠佳。因此在模型的建立之前，我们采用BorderlineSMOTE 来平衡数据集中客户违约数据和未违约数据之间相差过大的问题。SMOTE 为合成少数类过采样技术，是在随机采样的基础上改进的一种过采样算法，而 BorderlineSMOTE 是过采样技术系列中专门针对边界区域少数类样本进行过采样的改进算法。其核心思想是：只对容易被误分的少数类样本，即位于决策边界附近的危险样本做插值扩增；插值只在危险样本与其同属少数类的 k 个近邻之间进行，从而既增加边界样本密度，又尽量避免把合成样本放到多数类区域。

对每一个少数类样本 x，在全部训练集上找其 m 个最近邻，统计其中多数类样本数 m'，若 $m'=m$，此时把 x 视为噪声，跳过；若 $\frac{m}{2}\le m'<m$，把 x 划入危险样本集合；若 $m'<\frac{m}{2}$，把 x 视为安全样本，跳过。对于危险集合中的样本 x，我们对齐进行合成，在违约类内部再搜索 k 个最近邻，随机挑选一个邻居 y_j，按照下面的插值公式生成新样本，同时我们规定过采样的比例为 50%，来进一步确定新样本的个数，具体的插值公式为：

$$x'=x+\delta\cdot(y_j-x),\quad \delta\sim U(0,1) \tag{11}$$

接下来，我们给出实现这一操作的伪代码：

表 5 BorderlineSMOTE 伪代码

BorderlineSMOTE 操作伪代码
def borderline_smote(X, y, m=5, k=5, ratio=1.0): minority, majority = X[y==1], X[y==0] danger = [x for x in minority if m/2 <= sum(y[get_knn(x, X, m)]==0) < m] new_samples = [x + np.random.rand()*(random.choice(get_knn(x, minority, k)) - x) for x in danger for _ in range(int(ratio))] return np.vstack([X, new_samples]), np.hstack([y, np.ones(len(new_samples))])

```
def get_knn(x, X, n):
        dists = np.linalg.norm(X - x, axis=1)
    return np.argsort(dists)[1:n+1]
```

在进行过采样后，得到总样本数 1054 条，其中违约样本 527 条，我们将有效数据集按照 8:2 分为训练集和测试集，设训练集为D=L$\bigcup$U，其中有违约标识的子集记为标记子集 $L=(x_i,y_i)_{i=1}^{n_l}, y_i\in(0,1)$，无标记子集 $U=x_{i=n_1+1}^{n}$，其对应值不可观测。接下来我们对原始特征中的指标进行分类，分为金融特征、逾期特征和个人特征，将这 11 条指标进行分类，具体情况详见下表。

表 6 指标含义

特征类别	具体特征	业务含义
金融特征	RevolvingUtilizationOfUnsecuredLines、DebtRatio、MonthlyIncome	无担保额度使用率、负债比、月收入逾期特征
逾期特征	NumberOfTime30-59DaysPastDueNotWorse NumberOfTimes90DaysL NumberOfTime60-89DaysPastDueNotWorse	不同周期逾期次数
个人特征	age、NumberOfOpenCreditLinesAndLoans、NumberRealEstateLoansOrLines、NumberOfDependents	年龄、信贷账户数、不动产贷款数、家属数

接下来，我们将 30-59 天逾期的次数、60-89 天逾期次数、90 天逾期次数将这些指标的次数进行加权相加，得到作为违约预测的核心信号，以此来减少特征维度，接着我们将逾期次数进行分箱处理，将连续的逾期次数转化为类别特征，提升模型对逾期程度的非线性拟合能力，最终我们保留 9 个核心特征。

2.4 GRU 模型的建立求解

我们给定 GRU 模型的重置门和更新门的定义公式为：

$$r_t=\sigma\left(W_r[h_{t-1},x_t]+b_r\right) \tag{12}$$

$$z_t=\sigma\left(W_z[h_{t-1},x_t]+b_z\right) \tag{13}$$

其中，$\sigma(x)=\dfrac{1}{1+\mathrm{e}^{-x}}$，其中 h_{t-1} 包含了过去的信息，r 为重置门，当 r_t 趋近于零时，模型会将过去的隐藏信息丢弃，只留下当前输入的信息。当 r_t 趋近于 1 时，认为过去的信息都是有用的，并将其添加到当前信息中。

接下来我们给出候选隐藏层状态和最终隐藏状态的具体公式：

$$\tilde{h}_t=\tanh\left(W[r_t\odot h_{t-1},x_t]+b\right) \tag{14}$$

$$h_t=(1-z_t)\odot h_{t-1}+z_t\odot\tilde{h}_t \tag{15}$$

其中，$\tilde{h}_t$ 主要包含了 t 时刻输入的 x_t 的信息和有针对性的对 $t-1$ 时刻的隐藏层状

态 h_{t-1} 的保留。$(1-z_t)h_{t-1}$ 表示对原本隐藏状态的选择性以往，$z_t h_t$ 表示对当前节点的候选隐藏状态进行选择性记忆，同样也会忘记一些不重要的。当 z_t 趋近于 1 时，表示长期的依赖一直存在，当 z_t 趋近于 0 时，表示忘记隐藏信息中一些不重要的信息。

接下来，我们给出输出层概率计算的具体公式：

$$\hat{p} = \sigma(W_{\text{out}} h_t + b_{\text{out}}) \tag{16}$$

Focal Loss 是从损失函数的角度来处理样本数据不平衡的问题，基于二分类交叉熵损失改变而来。Focal Loss 函数可以通过调节焦点参数 γ，来改变难以采样的比例，从而使得模型在训练时专注于对难以采样的学习，具体的计算公式为：

$$\text{FL}(p_t) = -\alpha_t (1-p_t)^{\gamma} \ln p_t \tag{17}$$

其中，调节因子为 $\alpha_t = y\alpha + (1-y)(1-\alpha)$，概率权重为 $p_t = y\hat{p} + (1-y)(1-\hat{p})$。接下来，我们给出在 GRU 模型在解决这一问题中具体权重的定义具体如下表：

表 7 GRU 模型指标权重定义

指标来源	权重定义
Focal Loss 模型参数	$\gamma = 1.5, \alpha = 0.75$
GRU 模型参数	$U = 24$
正则化定义	$Dropout = 0.35$ ， $l_2 = 0.001$
非线性拟合定义	$Dense = 12$

接下来我们需要确定违约判别模型的判别指标，除了现有常用的判别指标，正确率、精确率、召回率、F1 值等等，在个人信贷违约预测领域，精确的违约判别临界点还有助于金融机构在信贷决策中实现更好的资源配置，降低潜在的信贷损失，同时优化客户关系管理。传统的违约判别模型往往预定一个标准违约阈值，比如说在逻辑回归中，该阈值通常被设置为 0.5，这意味着当预测的违约概率超过这个界限时，系统将认定该客户可能违约。这种做法背后的逻辑前提是数据样本是均衡的。因此，为了达到样本均衡，通常会采用特定的采样或代价敏感的方法策略[15-16]。文献[15]中采用 G-mean 统计量作为模型精度的评估标准，因为它综合了真阳率和真负率的几何平均值，从而能够全面反映违约判别模型的性能，G-mean 的具体计算方法如下：

$$G-mean = \sqrt{\frac{TN}{TN+FP} \times \frac{TP}{TP+FN}} = \sqrt{\text{TPR} \cdot \text{TNR}} \tag{18}$$

其中，TP、FP、TN、FN 分别为正确预测为分别表示正确预测为违约、错误预测为违约、正确预测为不违约、错误预测为不违约的实例数。

同时在参考文献[4],[5]中分别引用 AUC 和违约误判率作为违约模型性能的评价指标，结合参考文献和上文内容，我们采用的评价指标具体如下表：

表 8 模型评价指标表

指标	含义
准确率	整体预测正确的比例
精确率	预测为违约的样本中，实际违约的比例
AUC	模型区分违约或正常的能力
违约召回率	实际违约的样本中，被预测出来的比例
违约漏判率	实际违约但被预测为正常的比例
F1-score	平衡精确率和召回率
G-mean	平均召回率和特异度

针对客户违约预测任务中信贷数据集类别分布失衡的特点，该模型在 GRU 时序网络基础上引入焦点损失函数，降低大量简单可分的正常客户样本在损失计算中的权重，使模型训练过程更加聚焦于数量稀少、识别难度更高的违约样本，以此提升模型对违约客户的识别能力。由于本研究使用的客户特征均为静态横截面数据，不存在真实时间维度，因此将多维客户特征构造为伪时序序列，把每一项特征视作时序序列内独立的时间步，送入 GRU 网络完成特征挖掘。GRU 依靠更新门与重置门的门控结构，捕捉不同客户特征之间非线性关联关系，充分挖掘金融属性、逾期记录、个人基础信息等特征组合下蕴含的违约风险信息。

FL-GRU 采用双层 GRU 堆叠的网络结构。模型输入层接收三维张量，张量维度依次为样本数量、特征数量与通道维度。第一层 GRU 设置 24 个隐藏单元，开启序列输出模式，保留全部时间步的特征信息，同时添加 Dropout 与 L2 正则化约束，抑制模型发生过拟合。第二层 GRU 设置 12 个隐藏单元，仅输出序列最后一个时间步的隐藏状态，完成时序特征的聚合提取。经过两层 GRU 提取得到的特征向量送入全连接层，全连接层设置 12 个神经元并使用 ReLU 激活函数，后续添加 Dropout 层进一步随机丢弃部分神经元输出，增强模型泛化能力。最后一层采用单个神经元搭配 Sigmoid 激活函数，输出取值在 0 至 1 之间，代表对应客户发生违约的概率。

模型采用自定义 Focal Loss 作为损失函数，损失公式引入调制因子与类别平衡权重，参数设置为调制因子 $\gamma = 1.5$，正负样本平衡权重 $\alpha = 0.75$。调制因子能够压低易分类样本的损失贡献，平衡权重用于调整正负样本基础损失占比，二者共同缓解样本不均衡带来的模型偏向问题。模型选用 Adam 优化器进行参数更新，学习率设定为 0.0008，模型训练过程监控 AUC 与损失两项指标，AUC 作为信贷风险评估任务的核心评价指标。同时设置类别权重，对违约样本赋予更高权重，与焦点损失形成双重机制，进一步改善类别不平衡带来的训练偏差。

模型最大训练轮次设置为 20 轮，批次大小设置为 128。训练过程引入三组

回调函数，提升训练稳定性与模型效果。早停回调函数持续监测验证集 AUC 指标，当连续 5 轮训练验证集 AUC 提升幅度小于 0.001 时，自动终止训练并回载验证集性能最优的模型权重，避免模型过拟合。学习率衰减回调在验证损失连续 3 轮不再下降时，将学习率乘以 0.6 进行衰减，最低学习率限制为1×10^{-6}，便于模型在后期精细收敛。模型保存回调函数会持续监测验证集 AUC，自动保存训练过程中最优模型文件，便于后续读取与推理预测。

模型完成训练后，不直接采用 0.5 作为违约判定阈值。在验证集上以 G-mean 为优化目标，遍历多个候选阈值，选取 G-mean 取最大值对应的阈值作为最优分类阈值。G-mean 综合兼顾违约样本召回率与正常样本特异度，更加适配不平衡信贷分类任务。将最优模型作用于测试集，输出全部客户的违约概率，使用寻优得到的最佳阈值将概率转化为二分类标签，判定客户是否违约。基于预测标签与真实标签，计算准确率、精确率、AUC、违约召回率、违约漏判率、F1 分数、G-mean 等多项评价指标，量化评估 FL-GRU 模型的风险识别效果，用于和 SGL 半监督 GAM、多模型集成遴选模型进行横向性能对比。

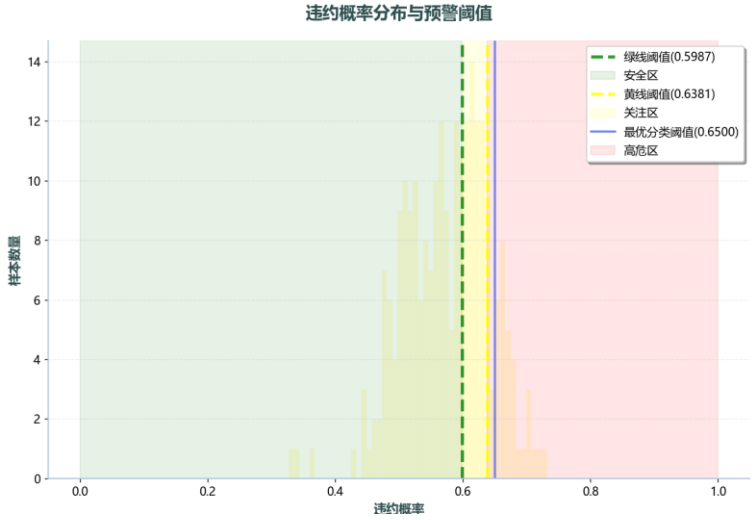


图 8 违约概率分布与预警阈值

图 8 表明了在 FL-GRU 模型中违约概率分布与预警阈值之间的关系，横轴表示违约概率，纵轴表示样本数量，整体分布呈现明显的右偏特征，大部分样本集中在违约概率较低的区域，说明数据集中低风险样本占多数，符合信用评分数据的常见分布规律；图中用绿色、黄色和红色三条垂直虚线划分出三个预警区间：绿色阈值线为 0.5987，之下为安全区，样本密度最高，代表绝大多数客户违约风险极低，黄色阈值线为 0.6381 至绿色阈值线之间为关注区，样本开始减少但仍有一定规模，需要加强监控，红色阈值线以上为高危区，虽然样本数量较少但违约概率显著升高，需立即采取风控措施；值得注意的是，最优分类阈值为 0.6500，位于黄色预警区间内，略低于黄色阈值，说明模型在平衡召回率与特异度时更倾向于将部分中等风险样本识别为潜在违约，这种设定有助于减少漏判，符合金融风控中“宁可误杀不可放过”的保守策略；整体而言，该图直观验证了预警机制的

有效性，通过颜色分区清晰区分风险等级，为金融机构提供了可操作的风险分层管理依据，特别是红色区域虽样本占比小但实际违约率高，需重点投入催收资源，而绿色区域可维持正常授信流程，实现精准风控与成本控制的平衡。

基于此，我们为银行贷款提供以下建议，对绿色区域，我们取 3 个模型中的最小分区阈值 0.5467，规定其为为低风险客户，维持正常授信，线上秒批额度，利率按基准下浮 5%并随借随还，减少人工干预；黄区的区间为 0.5467-0.65 的约 10%中风险客户，暂停自动提额，改为月度人工复核，要求补交近三月银行流水与资产证明，利率上浮 30%并追加保证保险，同时短信提醒还款；红区的约 35%高风险客户，立即冻结未用额度，七天内现场尽调，要求提前部分还款或追加房产抵押，否则启动诉讼保全，并列入行业黑名单，实现风险与收益精准匹配。

表 9 评价指标表

模型	准确率	精确率	AUC	召回率	误判率	F1 值	G-mean
FL-GRU	0.8930	0.3384	0.7965	0.6429	0.3571	0.6725	0.6500

通过该表可以看出，FL-GRU 模型在全部 7 项指标上都表现最好，AUC 0.7965、召回率 64.29%、误判率 35.71%、G-mean 为 0.6500 均为最高值，说明它既能有效排序，也能捕捉风险。它的准确率 89.30%和精确率 33.84%也明显高于 SGL 模型，这意味着模型更好地区分出了违约和正常客户，并且能够更准确地找出真正的违约者，同时避免误判太多好客户。最后，我们给出 FL-GRU 模型的训练与验证损失曲线，具体如下图。

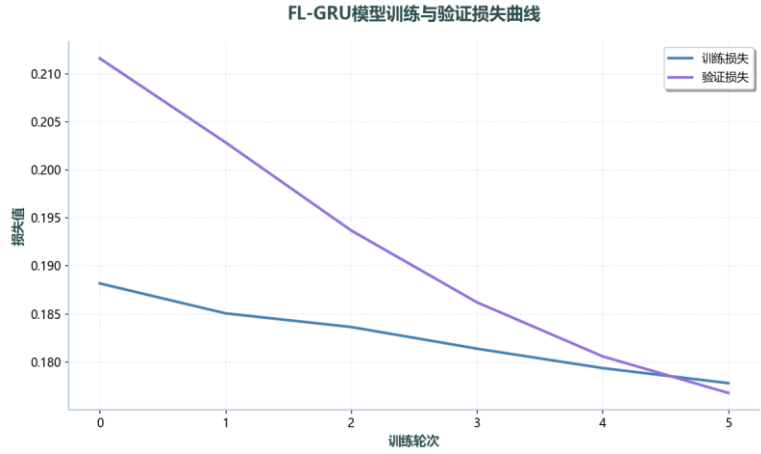


图 9 FL-GRU 模型损失曲线

2.5 总结体会

本文通过借鉴了参考文献[5]提出的 FL-GRU 建模框架，针对信用债违约样本极度不平衡问题，构建以 Focal Loss 为损失函数、双层 GRU 为骨干网络的违约概率预测模型实验结果表明，该模型在保持高 AUC 的同时显著降低违约漏判率，验证了其在信用债违约风险早期识别中的有效性与稳健性。