哈　尔　滨　理　工　大　学　理　学　院

专　业　实　验　报　告

课程名称	**统计模型及预测**		总 评 成 绩
实验题目	**时间序列预测**		
实 验 者	xxx	班级、学号	**统计 23-2** xxxxxxxxxx
时　　间	**2026 年 11 月 2 日**	地　　点	**新主楼 C811**

报告要求及时、认真、完整的完成。报告的主要内容参考如下：①实验目的；②实验原理；③实验仪器；④实验步骤；⑤数据处理（原始数据附后）；⑥实验结果及误差处理；⑦讨论收获、建议等。

一、实验目的

1.使学生综合掌握各种时间序列预测方法的操作过程和软件基本使用方法；

2.分别建立不同的时间序列预测模型，并进行相应的比较和分析对不同方法的预测结果进行评价；

3.深入剖析趋势预测模型结果及应用价值；

4.掌握季节变动预测相关软件的基础用法；

5.通过 MAPE 对比模型精度，分析参数对预测结果的影响。

二、实验原理

回归分析需要找到明确影响因素；当影响因素复杂、数据不可得时，采用时间序列分析。基本假设：事物过去变化规律将延续到未来。时间序列平滑法多用于短期预测，消除序列不规则随机扰动。

1.移动平均法

（1）简单平均法

给出时间序列 n 期的资料 $Y_1,Y_2,\cdots Y_{n-1},Y_n$，选择钱 T 期作为试验数据，计算平均值用以测定 T+1 期的数据，即

$$\overline{Y}=\sum_{i=1}^{T}Y_i/T=F_{T+1}$$

其中，$\overline{Y}$ 是钱 T 期的平均值；F_{T+1} 为第 T+1 期的估计值，也就是预测值。简单平均法是利用上述式子计算 T 期的平均值作为下一期即 T+1 期预测值的方法。

时间	存储上期数据	本期输入数据	输出
T		$Y_1, Y_2, \cdots Y_T$	$F_{T+1} = \sum_{i=1}^{T} Y_i / T$
$T+1$	T, F_{T+1}	Y_{T+1}	$F_{T+2} = \dfrac{T \times F_{T+1} + Y_{T+1}}{T+1}$
$T+2$	$T+1, F_{T+1}$	Y_{T+2}	$F_{T+2} = \dfrac{T \times F_{T+2} + Y_{T+2}}{T+2}$
……	……	……	……

（2）简单移动平均法

移动平均法是对简单平均法加以改进的预测方法。它保持半均的期数不变，总为下期，而使所求的平均值随时间变化不断移动。其公式为：

$$F_{T+1} = \frac{Y_1 + Y_2 + Y_3 + \cdots + Y_T}{T} = \frac{1}{T}\sum_{i=1}^{T} Y_i$$

若预测第 T+2 期，则

$$F_{T+2} = \frac{Y_2 + Y_3 + \cdots + Y_T + Y_{T+1}}{T} = \frac{1}{T}\sum_{i=2}^{T+1} Y_i$$

可以将简单移动平均预测方法归纳起来，

时间	移动平均公式	预测
T	$\bar{Y} = \dfrac{Y_1 + Y_2 + Y_3 + \cdots + Y_T}{T}$	$F_{T+1} = \bar{Y} = (\sum_{i=1}^{T} Y_i) / T$
$T+1$	$\bar{Y} = \dfrac{Y_2 + Y_3 + \cdots + Y_{T+1}}{T}$	$F_{T+2} = \bar{Y} = (\sum_{i=2}^{T+1} Y_i) / T$
$T+2$	$\bar{Y} = \dfrac{Y_3 + Y_4 + \cdots + Y_{T+2}}{T}$	$F_{T+3} = \bar{Y} = (\sum_{i=3}^{T+2} Y_i) / T$
……	……	……

简单移动平均法是利用时序前 T 期的平均值作为下一期预测值的方法，其数据存储量比简单平均法少，只需一组 T 个数据。T 是平均的期数，亦即移动步长，其作用为平滑数据，其大小决定了数据平滑的程度。T 越小，平均期数少，得到的数据越容易保留原来的波动，数据相对不够平滑;T 越大即移动步长越长，得到的数据越平滑。

简单移动平均预测实际上是通过当期预测误差修正当期预测值得到下一期的预测值。这是简单移动平均法的一个**优点**，通过误差不断修正得到新的预测值。其**不足**在于往往存在滞后问题，即实际序列已经发生大的波动，而预测结果却不能立即反映。

2.指数平滑法

（1）一次指数平滑

一次指数平滑也称作单指数平滑，简记为 SES，其公式可以由简单移动平均公式推导得出，即

$$F_{t+1}=F_t+\frac{1}{N}(Y_t-Y_{t-N})$$

其中，N 为移动步长 T；t 为任意时刻。

$$F_{t+1}=\alpha Y_t+(1-\alpha)F_t$$

上式是一次指数平滑公式，也是预测模型。其中 α 是平滑指数；F_t 是 t 时刻的一次指数平滑值。平滑值常记作 S_t，上式也可以写成 $S_{t+1}=\alpha Y_t+(1-\alpha)S_t$。一次指数平滑法预测第 t+1 期的平滑值作为当期的预测值。

表 4—12　　各种指数平滑法的比较

方　法		数据特征	预测模型	平滑值	参数估计	特点及局限
一次指数平滑		平稳 非季节性	$F_t=S_t=\alpha Y_t+(1-\alpha)S_{t-1}$	$S_t=\alpha Y_t+(1-\alpha)S_{t-1}$		α 值不变，只能预测一期
二次指数平滑	布朗单一参数指数平滑	线性趋势 非季节性	$F_{t+m}=a_t+b_tm$	$S_t^{(1)}=\alpha Y_t+(1-\alpha)S_{t-1}^{(1)}$ $S_t^{(2)}=\alpha S_t^{(1)}+(1-\alpha)S_{t-1}^{(2)}$	$a_t=2S_t^{(1)}-S_t^{(2)}$ $b_t=\frac{\alpha}{1-\alpha}[S_t^{(1)}-S_t^{(2)}]$	只有一个平滑常数 α，使用简单，反映数据的线性趋势
	霍特双参数指数平滑	线性趋势 非季节性	$F_{t+m}=S_t+b_tm$	$S_t=\alpha Y_t+(1-\alpha)(S_{t-1}+b_{t-1})$ $b_t=\gamma(S_t-S_{t-1})+(1-\gamma)b_{t-1}$		有两个平滑常数 α、γ，对趋势直接平滑，比布朗单一参数指数平滑法灵活。
三次指数平滑	布朗单一参数指数平滑	非线性趋势 非季节性	$F_{t+m}=a_t+b_tm+\frac{1}{2}c_tm^2$	$S_t^{(1)}=\alpha Y_t+(1-\alpha)S_{t-1}^{(1)}$ $S_t^{(2)}=\alpha S_t+(1-\alpha)S_{t-1}^{(2)}$ $S_t^{(3)}=\alpha S_t^{(2)}+(1-\alpha)S_{t-1}^{(3)}$	$a_t=3S_t^{(1)}-3S_t^{(2)}+S_t^{(3)}$ $b_t=\frac{\alpha}{2(1-\alpha)^2}[(6-5\alpha)S_t^{(1)}-(10-8\alpha)S_t^{(2)}+(4-3\alpha)S_t^{(3)}]$ $c_t=\frac{\alpha^2}{(1-\alpha)^2}[S_t^{(1)}-2S_t^{(2)}+S_t^{(3)}]$	只有一个平滑常数，可反映数据的非线性趋势，较实用
	温特线性和季节性指数平滑	线性趋势 季节性	$F_{t+m}=(S_t+b_tm)I_{t-L+m}$	$S_t=\alpha\frac{Y_t}{I_{t-L}}+(1-\alpha)(S_{t-1}+b_{t-1})$ $b_t=\gamma(S_t-S_{t-1})+(1-\gamma)b_{t-1}$ $I_t=\beta\frac{Y_t}{S_t}+(1-\beta)I_{t-L}$		适用于季节变动和趋势变动数据，平滑常数 α、β、γ 的最优值较难确定

（2）二次指数平滑法

一次指数平滑法是直接利用平滑值作为预测值的一种预测方法，二次指数

平滑法则不同，它是用平滑值对时序的线性趋势进行修次指数平滑也称为线性指数平滑。

一次和二次指数平滑值都落后于实际值。布朗(Brown)单一参数线性指数平滑比较好地解决了这一问题。其平滑公式为:

$$S_t^{(1)} = \alpha Y_t + (1-\alpha) S_{t-1}^{(1)}$$
$$S_t^{(2)} = \alpha S_{t\ t}^{(1)} + (1-\alpha) S_{t-1}^{(2)}$$

其中，$S_t^{(1)}$ 为一次指数平滑值，$S_t^{(2)}$ 为二次指数平滑值

由两个平滑值可以计算线性平滑模型的两个参数：

$$at = S_t^{(1)} + [S_t^{(1)} - S_t^{(2)}] = 2S_t^{(1)} - S_t^{(2)}$$
$$bt = \frac{\alpha}{1-\alpha}[S_t^{(1)} - S_t^{(2)}]$$

得到线性平滑模型：$F_{t+m} = a_t + b_t m$

其中，m 为预测的超前期数。上式就是布朗单一参数线性指数平滑的预测模型，通常称为线性平滑模型。

移动平均法是以最近 n 期资料的算术平均值或加权平均值作为下一期的预测值，使用简单，并且可以消除数据的季节变动、不规则变动的影响。指数平滑法与移动平均法相似，不同点是采用该方法预测时，最近的资料所占比重较大。本方法所需保留的资料少，计算方便，是一种较为经济的短期预测方法。

如果数据是比较平稳的，没有较大的波动，则可以采用一次指数平滑法。如果数据具有某种趋势但无季节性变动，则布朗单一参数线性和非线性平滑法是较为实用的方法。这主要是因为它们都只有一个参数（霍特法和温特法参数个数均大于 1），使用比较方便。若数据的趋势变动能延续一段时期，那么这两种方法也可以用于中期甚至长期预测。相比之下，三次指数平滑可以比二次指数平滑更好地预测拐点，因为它是非线性平滑。

对于有季节性的数据，温特法是唯一得到广泛应用的方法。它需要三个平滑参数，在确定α,β,γ的最优值时要进行多次组合试验，因而计算工作量较大。并且，一旦最优参数值确定，即使数据发生根本变化，也很难改变参数值。计算机软件的应用，可以帮助我们自动选择合适的参数，这避免了不断反复试验的麻烦。预测中，通常根据数据特征选择适用的平滑方法.当时间序列呈现上升或下降趋势，直接以时间 t 作为自变量建立模型，假定历史趋势可以外推至未来。

3.趋势模型类型

（1）直线趋势模型

（2）非线性趋势模型

- 二次曲线模型
- 三次曲线模型

- 幂函数曲线模型
- 对数曲线模型
- 双曲线模型
- 指数曲线模型

（3）有增长上限的曲线趋势模型

- 修正指数曲线模型
- 龚珀兹曲线模型
- 皮尔曲线模型

4.模型选择

（1）图像识别法

图形识别法是从实际时间序列的数据出发选择模型的方法。该方法将时间序列的数据绘制成以时间 t 为横轴，时序观察值为纵轴的曲线图，观察其变化，并与各类函数曲线模型的图形进行比较，选择较为合适的模型。实际的观测对象往往无法通过图形直观确认为某种模型，所以，一般初选几个模型，然后再通过模型分析确认合适的模型。

（2）阶差法

阶差法是从模型的特点出发，观察时间序列的特点，并将其与各类模型阶差的特点比较以选择适宜模型的方法。

5.模型分析评价

模型分析评价有两个方面:一是模型对历史数据的拟合，二是型对未来趋势的表现。若所选的趋势模型对历史数据拟合较好，又符合其未来的发展趋势，则可以直接用于预测。

（一）对历史数据拟合的分析

分析模型对历史数据的拟合程度，可以采用直观判断法和误差分析法

（1）直观判断法

将时间序列历年实际观测值与模型相应的估计值通过列表或绘图进行比较，可认为与时间序列实际值接近的模型，对历史数据的拟合程度高。

（2）误差分析法

模型对历史数据的拟合程度，通过误差分析可以得到较为精确的判断。若 MAPE<10，则认为模型的预测精度较高。不同的模型，MAPE 小者为拟合程度高的模型。

$$MAPE = (\sum_{i=1}^{n} | \frac{y_i - \hat{y}_i}{y_i} | / n) \times 100$$

（二）对未来趋势反映的分析

（1）模型对序列近期趋势的反映

从模型对时间序列近期数据的拟合，看其是否与时间序列的发展变化一致。一般来说，对近期的拟合好于整个样本期，表明模型在近期对序列的变化描述更好，如果误差大大减小，则表明对近期趋势的反映能力增强。这一分析

也可以利用直观判断和误差分析进行，只是将时间范围限定在近期加以考察。

（2）试预测

试预测可以从两个不同角度进行，一是建模时预留一部分数据作为测试集，利用其余数据建模**外推**，分析模型对测试集数据的拟合，作为试预测结果的判定。一般这种方法在数据量较多时才能使用。二是利用全部数据建模，给时间变量 t 赋予未来不同值，并将其代入模型，得到今后若于时期的估计值。

1）若模型接近预测对象近期的实际变化，且能很好地解释它今后的变化，则具有较强的预测能力。

2）若模型偏离预测对象近期实际变化又无法反映其今后变化，则应淘汰。

3）若模型虽近期有所偏离，但能预测对象今后的变化，则可以考虑调整模型，如删减部分远期数据，重新建模以提高模型对时序近期数据的拟合程度等。

试预测也可以通过在开始建模时预留一部分近期数据，建立型后，外推到这一段时期，分析评价

季节变动，是指客观事物由于自然条件、生产条件和生活习惯等因素的影响，随着季节的转变而呈现的周期性变动，这种周期通常为 1 年，或者说 12 个月、4 个季度。季节变动是客观事物常有的一种变化规律。

季节变动的特点是有规律性，每年重复出现，其表现为逐年同月(或季)有相同的变化方向和大致相同的变化幅度。时间序列的季节变动可以直观地从其随时间变化的曲线图上看出。时间序列的季节性往往并不单独存在，而是伴随趋势变动存在。

6.季节性交乘趋向模型

（一）模型形式

季节性交乘趋向模型是趋势和季节的乘法模型，其形式如下：

$$\hat{Y}_t = (a+bt)\bullet f_i$$

式中 $(a+bt)$ 是时间序列趋势变动部分，可以是线性的，也可以是非线性的；f_i 是时间序列各月（或季）的季节指数。最简单的计算公式如下：

$$f_i = \frac{F_i + F_{i+T} + \cdots + F_{i+(m-1)T}}{m}，\ i = 1,2,\cdots 12 或 i = 1,2,3,4$$

式中，F 是各期实际的季节指数，由当期实际值除以趋势值得到，反应当期由于季节影响实际值高于或低于趋势值的比例；T 是季节周期的长度，月度数据为 12，季度数据为 4；m 是季节周期的个数，即年份数；f_i 是理论季节指数。

（二）适用条件

季节性交乘趋向模型适用于既有季节变动又有趋势变动，且季节变动幅度随趋势增加而加大的时间序列。利用这种模型预测，至少需要 5 年的分月（或季）数据。

（三）应用

（1）时序变化分析

（2）建模，建立趋势模型；计算季节指数

（3）预测

三、实验仪器

Python3.10

四、实验步骤

本次实验针对消费品指数月度时间序列开展时间序列平滑预测，遵循时间序列建模通用流程开展实验，具体步骤如下。

1）收集整理样本数据，检查异常点，绘制时序图观察变量变化特征。本次实验应用教材 97 页表 4-3 中的时间序列数据，预测对象为消费品指数，采用 1993 年 1 月至 1995 年 11 月的月度原始时序数据。导入原始数据构建数据表，对数据开展核查，核对数值完整性，样本无缺失值与异常离群点。基于原始数据绘制时序曲线图，观察消费品指数随时间的波动变化，序列存在波动，局部带有微弱下降趋势，适合采用移动平均、指数平滑类单变量时间序列模型开展预测。

2）初选模型，完成模型参数估计。根据序列波动特征，选取三类时间序列平滑模型，分别为简单移动平均模型、一次指数平滑模型、布朗单一参数二次指数平滑模型。移动平均模型设置三组窗口参数$T=3$、$T=5$、$T=12$；一次指数平滑选取三组平滑系数$\alpha=0.3$、$\alpha=0.5$、$\alpha=0.7$；布朗二次指数平滑平滑系数选取$\alpha=0.3$。采用 Python 编程实现各模型算法，完成参数计算，得到各模型样本内一步预测拟合结果。

3）模型检验与模型调整。本实验使用单变量时序平滑模型，不存在回归 T 检验 F 检验拟合优度 D.W 检验异方差检验以及多重共线性检验。依靠样本拟合图像直观判断模型对原始序列的跟随效果，对比不同参数下模型拟合曲线与实际序列的贴合程度。根据图像表现可以看到大窗口移动平均过度抹平序列短期波动，小窗口移动平均可以更好捕捉短期变化。一次指数平滑增大α会提高近期数据权重，对序列变化响应更加灵敏。布朗二次指数平滑可以捕捉序列隐含的线性趋势。不适合的参数会出现拟合滞后、过度平滑现象，本实验通过多组参数对比，筛选拟合表现更优的参数组合。

4）预测精度评价，计算误差评价指标。本实验主要采用平均绝对百分比误差 MAPE 作为核心评价指标，分别计算全数据集、1994 年 1 月至 1995 年 11 月评估子区间两组 MAPE。对比不同模型不同参数条件下误差指标的大小，MAPE 数值越低，代表模型整体预测精度越高。

5）点预测，结合业务常识定性分析预测结果合理性。使用布朗单一参数二次指数平滑模型开展未来 6 期点外推预测，得到消费品指数后续月度预测数值。结合时序后期逐步走低的变化特点，分析外推结果是否符合序列发展态势。综合图像拟合效果与 MAPE 精度指标，筛选综合性能最优模型用于时序预测。

五、数据处理

应用教材表格 4-3 中的我国 1993-1995 年各月的消费品指数时序数据进行实验，的原始数据如下：

表 1 原始数据表

时间	指数	时间	指数
1993.1	1.2049	1994.7	1.2985
1993.2	1.1	1994.8	1.3399
1993.3	1.2206	1994.9	1.3644
1993.4	1.3092	1994.10	1.3739
1993.5	1.318	1994.11	1.41
1993.6	1.327	1994.12	1.365
1993.7	1.301	1995.1	1.3439
1993.8	1.273	1995.2	1.2828
1993.9	1.233	1995.3	1.3133
1993.10	1.236	1995.4	1.3232
1993.11	1.248	1995.5	1.3063
1993.12	1.354	1995.6	1.2799
1994.1	1.2196	1995.7	1.2973
1994.2	1.3027	1995.8	1.273
1994.3	1.239	1995.9	1.2577
1994.4	1.2434	1995.10	1.2589
1994.5	1.2614	1995.11	1.2455

六、实验结果

6.1 移动平均预测

首先，利用移动平均进行预测所使用试用 $T=3, T=5, T=12$ 分别进行移动平均预测，具体结果如下图所示。

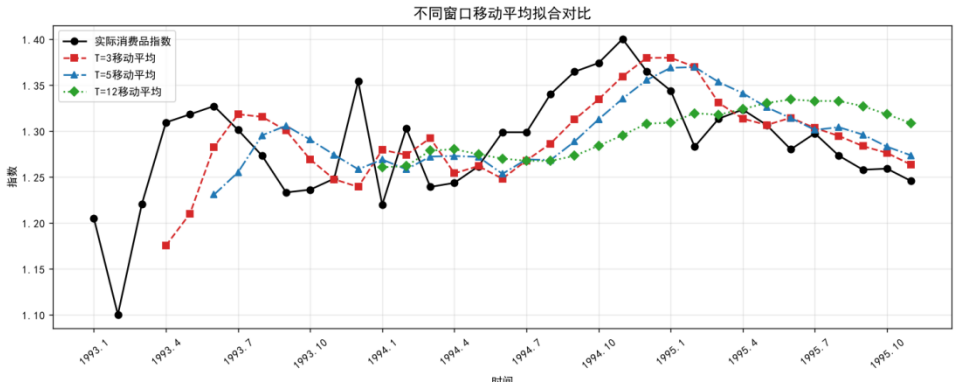


图 1 消费品指数在不同窗口移动平均拟合对比图

通过上图可以观察到 $T=12$ 的曲线走势最为平缓，明显滞后实际序列的波峰波谷。$T=3$ 曲线跟随实际指数波动的能力更强，和真实值贴合程度更高，和 MAPE 误差计算得到的结论保持一致。移动平均方法缺点在于存在天然滞后效应，窗口越大滞后现象越明显。

表 2 消费品指数及拟合值

时间	指数	T=3	T=5	T=12
1993.1	1.2049			
2	1.1			
3	1.2206			

4	1.3092	1.175167		
5	1.318	1.209933		
6	1.327	1.2826	1.23054	
7	1.301	1.318067	1.25496	
8	1.273	1.315333	1.29516	
9	1.233	1.300333	1.30564	
10	1.236	1.269	1.2904	
11	1.248	1.247333	1.274	
12	1.354	1.239	1.2582	
1994.1	1.2196	1.279333	1.2688	1.260392
2	1.3027	1.273867	1.25812	1.261617
3	1.239	1.2921	1.27206	1.278508
4	1.2434	1.253767	1.27266	1.280042
5	1.2614	1.2617	1.27174	1.274558
6	1.2738	1.247933	1.25322	1.269842
7	1.2985	1.259533	1.26406	1.265408
8	1.3399	1.2779	1.26322	1.2652
9	1.3644	1.304067	1.2834	1.270775
10	1.3739	1.334267	1.3076	1.281725
11	1.41	1.3594	1.3301	1.293217
12	1.365	1.382767	1.35734	1.306717
1995.1	1.3439	1.382967	1.37064	1.307633
2	1.2828	1.372967	1.37144	1.317992
3	1.3133	1.330567	1.35512	1.31635
4	1.3232	1.313333	1.343	1.322525
5	1.3063	1.306433	1.32564	1.329175
6	1.2799	1.314267	1.3139	1.332917
7	1.2973	1.303133	1.3011	1.331425
8	1.273	1.2945	1.304	1.331325
9	1.2577	1.2834	1.29594	1.32575
10	1.2589	1.276	1.28284	1.316858
11	1.2455	1.2632	1.27336	1.307275
12	1.2367	1.254033	1.26648	1.296567
1996.1		1.247033	1.25436	1.284875

平均期数 T 越大，各期估计值之间的差异越小，曲线越平滑。消费品指数序列基本在水平方向波动，但波动幅度较大，因此移动步长稍小的预测效果较好。计算 1994 年 1 月-1995 年 12 月移动步长分别为 3，5，12 的 MAPE 为 2.381 9，2.929 6，3.649 5。可以看出，预测精度在$T=3$时最高。选定预测步长最小的进行预测，1996 年消费品指数为 1.247，实际值为 1.192。还可以看出，

简单移动平均法无论移动步长大小，都存在预测滞后问题。这对于其实际应用造成了很大影响。移动平均模型简记为 MA，移动步长为 T。模型记为 MA 。本例模型可记为 $MA(3)$ 。

表 3 移动平均 MAPE 结果

模型参数	MAPE（%）
T=3	3.0447
T=5	3.2938
T=12	3.616

窗口 T 等于 3 时全周期 MAPE 为 3.0447，评估区间 MAPE 为 2.5751。窗口 T 等于 5 时误差出现上升，窗口 T 等于 12 的 MAPE 在全部模型当中达到最高，评估子区间已经达到 4.0656。原因在于 T 数值越大，移动平均对历史数据做更强的平滑处理，会滞后于序列短期波动变化。消费品指数样本本身月度波动明显，过大窗口会丢失短期变化信息，造成预测误差变大。针对本组数据，移动平均模型当中 T 等于 3 的小窗口预测效果最优。

6.2 一次指数平滑预测

分别取三组平滑系数 $\alpha=0.3$ 、 $\alpha=0.5$ 、 $\alpha=0.7$ ，得到 1994-1995 年各月份的第一次指数平滑值，结果如下图。

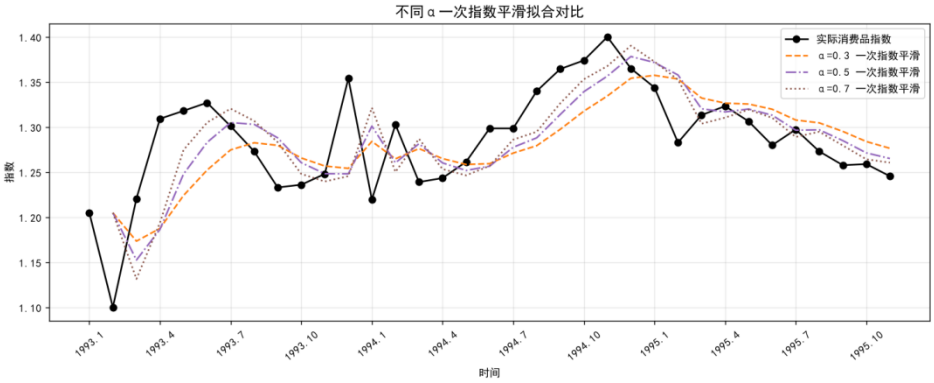


图 2 一次指数平滑拟合对比

$\alpha=0.7$ 的曲线跟随实际序列变化反应最快 $\alpha=0.3$ 曲线更加平滑，对变化响应迟钝。一次指数平滑只适合水平型时间序列，如果序列带有趋势，模型会持续出现滞后偏差，这也是一次指数平滑整体误差高于布朗二次指数平滑的原因。

更进一步，我们截取后段评估样本进行观察，同样可以看到 $\alpha=0.7$ 的曲线对波动跟踪效果最好。该时间段是模型性能的重点考察区间，更能体现模型对近期数据的预测能力。

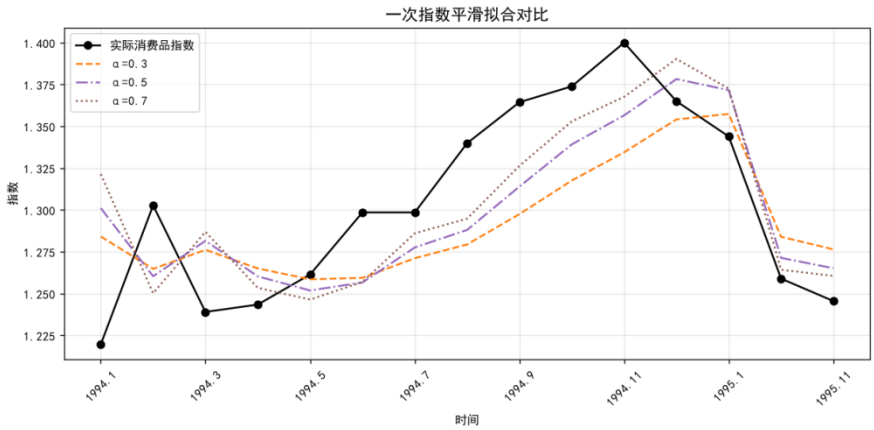


图 3 一次指数平滑拟合对比图

接下来，我们计算一次指数平滑三组参数的 MAPE 值。可以看到，随着平滑系数α增大，模型 MAPE 整体逐步下降。$\alpha=0.7$时，全周期 MAPE 为 2.9731，评估区间 MAPE 为 2.5347，在一次指数平滑三组参数中精度表现最好。α数值越大，模型会赋予近期观测值更高权重，可以更快跟上序列的波动变化。本组消费品指数存在较多月度震荡，提高近期数据权重有利于降低预测误差。但是α过高也会放大随机噪声的影响，实际使用需要权衡。

表 4 一次指数平滑 MAPE 值

平滑系数α	MAPE（%）
0.3	3.3323
0.5	3.0529
0.7	2.9731

6.3 二次指数平滑法预测

仍使用上述数据，取$\alpha=0.3$，一次平滑和二次平滑的初始值均为序列第一期实际值。在这里我们给出所有消费品指数的拟合值，进行更进一步的对比。

时间	指数	MA（3）	MA（5）	MA（12）	SES 0.3	SES 0.7	BROWN1STEP
1993.1	1.2049	-	-	-	-	-	-
1993.2	1.1	-	-	-	1.2049	1.2049	1.160842
1993.3	1.2206	-	-	-	1.17343	1.13147	1.18443
1993.4	1.3092	1.175167	-	-	1.18758	1.193861	1.236455
1993.5	1.318	1.209933	-	-	1.22406	1.274598	1.272191
1993.6	1.327	1.2826	1.23054	-	1.25224	1.304979	1.297604
1993.7	1.301	1.318067	1.25496	-	1.27467	1.320394	1.301782
1993.8	1.273	1.315333	1.29516	-	1.28257	1.306818	1.291999
1993.9	1.233	1.300333	1.30564	-	1.2797	1.283145	1.268695
1993.1	1.236	1.269	1.2904	-	1.26569	1.248044	1.255324
1993.11	1.248	1.247333	1.274	-	1.25678	1.239613	1.252073
1993.12	1.354	1.239	1.2582	-	1.25414	1.245484	1.294633
1994.1	1.2196	1.279333	1.2688	1.2603	1.28410	1.321445	1.264383

1994.2	1.3027	1.273867	1.25812	1.2616	1.26475	1.250154	1.280432
1994.3	1.239	1.2921	1.27206	1.2785	1.27613	1.286936	1.263546
1994.4	1.2434	1.253767	1.27266	1.2800	1.26499	1.253381	1.254911
1994.5	1.2614	1.2617	1.27174	1.2745	1.25851	1.246394	1.257203
1994.6	1.2985	1.247933	1.25322	1.2698	1.25938	1.256898	1.274287
1994.7	1.2985	1.267767	1.269	1.2674	1.27111	1.286019	1.284836
1994.8	1.3399	1.286133	1.26816	1.2672	1.27933	1.294756	1.308624
1994.9	1.3644	1.3123	1.28834	1.2728	1.29750	1.326357	1.333384
1994.10	1.3739	1.334267	1.31254	1.2837	1.31757	1.352987	1.352298
1994.11	1.4	1.3594	1.33504	1.2952	1.33447	1.367626	1.374472
1994.12	1.365	1.379433	1.35534	1.3079	1.35412	1.390288	1.372935
1995.1	1.3439	1.379633	1.36864	1.3088	1.35739	1.372586	1.362606
1995.2	1.2828	1.369633	1.36944	1.3192	1.35334	1.352506	1.330199
1995.3	1.3133	1.330567	1.35312	1.3175	1.33218	1.303712	1.322864
1995.4	1.3232	1.313333	1.341	1.3237	1.32651	1.310424	1.322567
1995.5	1.3063	1.306433	1.32564	1.3304	1.32552	1.319367	1.31538
1995.6	1.2799	1.314267	1.3139	1.3341	1.31975	1.31022	1.299953
1995.7	1.2973	1.303133	1.3011	1.3325	1.30779	1.288996	1.297898
1995.8	1.273	1.2945	1.304	1.3324	1.30464	1.294809	1.28663
1995.9	1.2577	1.2834	1.29594	1.3269	1.29515	1.279543	1.273457
1995.1	1.2589	1.276	1.28284	1.3180	1.28391	1.264253	1.266088
1995.11	1.2455	1.2632	1.27336	1.3084	1.27641	1.260506	1.256202

对消费品指数时序预测结果分别开展纵向与横向对比分析。从纵向看，通过观察各模型在时间轴上的预测序列与实际指数的变化趋势。移动平均方法存在明显滞后效应，当指数快速上升或回落时，预测值跟不上真实值的突变；指数平滑与布朗平滑可以更快响应序列变化，跟踪能力更强。在 1993 年末、1994 年下半年这些指数剧烈波动的时段，所有模型的预测偏差均有不同程度放大，说明这一类平滑类模型对突变型波动的捕捉能力有限；从横向看，在同一时间截面上，对比 MA（3）、MA（5）、MA（12）、不同平滑系数的一次指数平滑、布朗平滑的预测结果。移动平均中，窗口越大，序列越平滑，但滞后性越强；窗口越小，对短期变化更敏感，但预测结果震荡更大。对于一次指数平滑，随着平滑系数α增大，模型赋予近期数据更高权重，响应速度加快；结合 MAPE 指标横向定量比较，$\alpha = 0.7$的一次指数平滑在本组模型中平均相对误差最低，预测精度最优。综合来看，小窗口移动平均、高系数指数平滑适合捕捉短期变动；大窗口移动平均更适合过滤噪声、观察长期趋势。

布朗单一参数二次指数平滑模型，全周期 MAPE 仅 1.8385，评估子区间 MAPE 低至 1.5296，在全部对比模型中误差最小。

该模型除水平分量之外额外引入趋势分量$\alpha = 0.3$，可以捕捉序列隐含线性变化。观察样本后期消费品指数整体呈现小幅下行态势，布朗二次平滑能够捕捉该趋势特征，因此拟合精度显著优于移动平均、一次指数平滑。

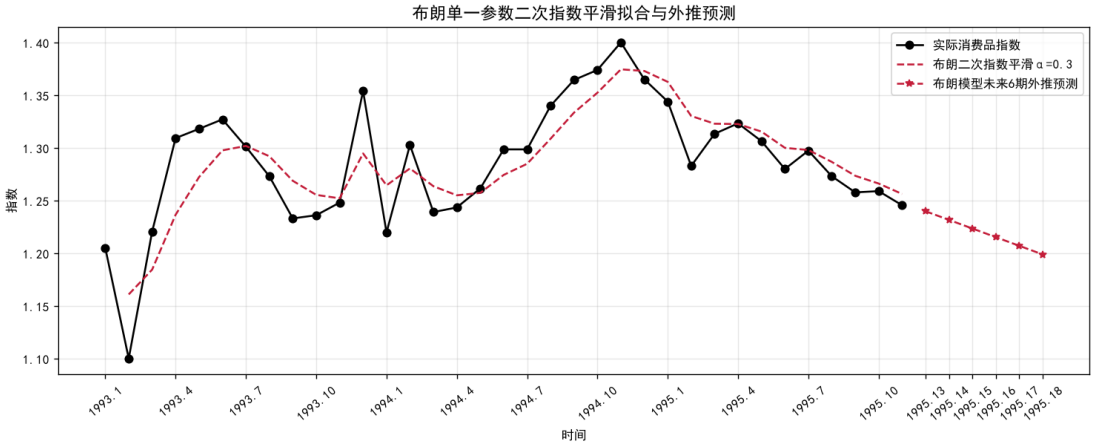


图 4 消费品指数布朗单一参数二次指数平滑拟合与外推预测图

由上图可知，样本内拟合曲线和原始消费品指数贴合程度高，残差整体较小。样本外未来 6 期预测呈现平稳下行的走向，符合序列尾部的变化规律。布朗二次指数平滑专门针对带有线性趋势的序列，弥补一次指数平滑无法处理趋势的缺陷。

布朗二次指数平滑模型计算得到期末水平 a_t 等于 1.247999，趋势系数 b_t 等于-0.008203，趋势值为负数，反映消费品指数后期呈现缓慢下降的线性变化特征。未来 6 期外推点预测结果如下表。

表 5 未来 6 期预测结果

预测期次	预测值
第 1 期	1.239796
第 2 期	1.231594
第 3 期	1.223391
第 4 期	1.215188
第 5 期	1.206985
第 6 期	1.198783

外推结果延续样本末尾的下降趋势，消费品指数将持续缓慢走低。该结果是基于历史时序模式外推得到，只适合做短期预测，时间拉长之后，现实中外部经济环境发生改变，序列原有趋势会被打破，长期外推预测可靠性会下降。

移动平均、指数平滑均属于单变量时间序列预测方法，仅仅依靠指标自身历史数据开展预测。模型不考虑外部影响因素，例如居民收入、物价政策等现实因素。如果未来外部条件发生重大变化，历史演变模式被打破，所有时序平滑模型预测结果都会出现较大偏差。

移动平均只适合短期预测，大窗口对突变响应差。一次指数平滑不能处理趋势序列。布朗二次指数平滑假定未来保持固定线性趋势，仅仅适合短期外推，不适合中长期预测。

综合全部精度指标与图形结果，针对本消费品指数数据集，布朗单一参数二次指数平滑 $\alpha = 0.3$ 为最优模型。

七、实验收获

本次实验以消费品指数时间序列为研究对象，运用移动平均、一次指数平滑 布朗一次平滑等经典时序预测模型完成建模 计算与对比分析。通过纵向观察预测序列随时间的变化趋势 横向对比不同参数与模型的预测误差，我对时间序列平滑预测方法有了更加完整 落地的理解。

从实验结果来看，移动平均模型存在显著的滞后特性。窗口长度越大，预测曲线越平稳，对随机噪声的过滤效果越好，但对序列拐点 短期突变的响应速度越慢。窗口缩小后，模型灵敏度提升，预测值波动随之放大。一次指数平滑受平滑系数α调控，α取值越大，近期观测值权重越高，模型对最新信息的跟踪能力越强。结合 MAPE 误差指标综合评判，在本消费品指数数据集下，$\alpha=0.7$的一次指数平滑模型平均相对误差最小，预测表现优于本组其他模型。同时我也意识到，这类平滑方法均建立在历史信息加权的基础上，属于依赖过往数据的外推方法，面对序列突发跳变时难以快速捕捉异动，存在固有的局限性，仅适合趋势相对稳定 无剧烈突变的短期预测场景。

在动手实现与数据分析的过程中，我跳出了课本上抽象的公式，真切体会到参数选择不是简单试错，而是在平滑降噪和趋势跟踪之间做权衡。起初我只关注数值计算是否正确，忽略了误差背后的模型机理。在逐行核对预测表 对比同一时点不同模型输出 梳理 MAPE 差异的过程中，我慢慢读懂每一条曲线 每一组误差数字背后的含义。横向对比让我学会定量评价模型优劣，纵向时序观察教会我从动态视角审视预测结果，而不再孤立看待单个预测值。

这次实验也让我收获了严谨的科研思维。时序预测没有万能最优模型，不存在一套参数适用于所有序列，模型选择必须贴合数据本身特征。数据清洗 结果制表 对比论证 误差解释，每一步都需要耐心，一个微小的计算偏差就会影响后续全部对比结论。我也认识到经典时序模型的边界。它们简洁易用，但能力有限，若要应对更复杂 非线性 带有多重周期的序列，还需要学习更加进阶的时序方法。

此次实验不只是一次课程任务，更是一次理论联系实践的历练。我巩固了时间序列分析的基础理论，熟悉了模型对比 误差评价的研究范式，培养了定量分析 客观论证的习惯。未来再做预测类研究时，我会先分析序列特征，合理选择模型与参数，重视模型假设与适用条件，理性看待预测结果，不盲目迷信模型输出。这份踏实求证 审慎分析的思维，也会成为后续统计学学习与科研实践中重要的积累。

指导老师：吕静

时间：2026 年 11 月 2 日

实验代码

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
plt.switch_backend('TkAgg')
import warnings
warnings.filterwarnings("ignore")

plt.rcParams["font.sans-serif"] = ["SimHei"]
plt.rcParams["axes.unicode_minus"] = False

raw_data = [
    ["1993.1", 1.2049], ["1993.2", 1.1000], ["1993.3", 1.2206],
    ["1993.4", 1.3092], ["1993.5", 1.3180], ["1993.6", 1.3270],
    ["1993.7", 1.3010], ["1993.8", 1.2730], ["1993.9", 1.2330],
    ["1993.10", 1.2360], ["1993.11", 1.2480], ["1993.12", 1.3540],
    ["1994.1", 1.2196], ["1994.2", 1.3027], ["1994.3", 1.2390],
    ["1994.4", 1.2434], ["1994.5", 1.2614], ["1994.6", 1.2985],
    ["1994.7", 1.2985], ["1994.8", 1.3399], ["1994.9", 1.3644],
    ["1994.10", 1.3739], ["1994.11", 1.4000], ["1994.12", 1.3650],
    ["1995.1", 1.3439], ["1995.2", 1.2828], ["1995.3", 1.3133],
    ["1995.4", 1.3232], ["1995.5", 1.3063], ["1995.6", 1.2799],
    ["1995.7", 1.2973], ["1995.8", 1.2730], ["1995.9", 1.2577],
    ["1995.10", 1.2589], ["1995.11", 1.2455]
]

df = pd.DataFrame(raw_data, columns=["time_str", "index"])
df["t"] = np.arange(len(df))
y_series = df["index"].values


def calc_mape(y_true, y_pred):
    mask = (~np.isnan(y_pred)) & (y_true != 0)
    yt = y_true[mask]
    yp = y_pred[mask]
    mape = np.mean(np.abs((yt - yp)/yt)) * 100
    return round(mape, 4)
```

```
def moving_average_pred(series, window):
    n = len(series)
    pred = np.full(n, np.nan)
    for i in range(window, n):
        pred[i] = np.mean(series[i-window:i])
    return pred


df["MA3"] = moving_average_pred(y_series, window=3)
df["MA5"] = moving_average_pred(y_series, window=5)
df["MA12"] = moving_average_pred(y_series, window=12)

mape_ma3 = calc_mape(y_series, df["MA3"].values)
mape_ma5 = calc_mape(y_series, df["MA5"].values)
mape_ma12 = calc_mape(y_series, df["MA12"].values)
print("===== 移动平均 MAPE 结果（%） =====")
print(f"T=3   MAPE = {mape_ma3}")
print(f"T=5   MAPE = {mape_ma5}")
print(f"T=12 MAPE = {mape_ma12}")


def single_exp_smooth(series, alpha):
    n = len(series)
    s = np.zeros(n)
    s[0] = series[0]
    pred = np.full(n, np.nan)
    for i in range(1, n):
        s[i] = alpha * series[i-1] + (1-alpha)*s[i-1]
        pred[i] = s[i]
    return pred


alpha_list = [0.3, 0.5, 0.7]
for a in alpha_list:
    colname = f"SES_{a}"
    df[colname] = single_exp_smooth(y_series, alpha=a)
```

```
mape_ses03 = calc_mape(y_series, df["SES_0.3"].values)
mape_ses05 = calc_mape(y_series, df["SES_0.5"].values)
mape_ses07 = calc_mape(y_series, df["SES_0.7"].values)
print("\n===== 一次指数平滑 MAPE 结果（%） =====")
print(f"α=0.3 MAPE = {mape_ses03}")
print(f"α=0.5 MAPE = {mape_ses05}")
print(f"α=0.7 MAPE = {mape_ses07}")



def brown_double_exp_smooth(series, alpha, forecast_horizon=6):
    n = len(series)
    s1 = np.zeros(n)
    s2 = np.zeros(n)
    pred_step1 = np.full(n, np.nan)
    s1[0] = series[0]
    s2[0] = series[0]
    a_t_list = []
    b_t_list = []
    for i in range(1, n):
        s1[i] = alpha * series[i] + (1-alpha)*s1[i-1]
        s2[i] = alpha * s1[i] + (1-alpha)*s2[i-1]
        a = 2*s1[i] - s2[i]
        b = (alpha/(1-alpha))*(s1[i] - s2[i])
        a_t_list.append(a)
        b_t_list.append(b)
        pred_step1[i] = a - b
    a_last = 2*s1[-1] - s2[-1]
    b_last = (alpha/(1-alpha))*(s1[-1] - s2[-1])
    future_pred = [a_last + b_last * m for m in range(1, forecast_horizon+1)]
    return pred_step1, future_pred, a_last, b_last



alpha_brown = 0.3
df["BROWN_1STEP"], brown_future, a_final, b_final =
brown_double_exp_smooth(y_series, alpha=alpha_brown, forecast_horizon=6)
mape_brown = calc_mape(y_series, df["BROWN_1STEP"].values)
print("\n===== 布朗二次指数平滑 α=0.3 =====")
print(f"样本内一步预测 MAPE = {mape_brown} %")
```

```
print(f"期末水平 a_t={round(a_final,6)}，趋势 b_t={round(b_final,6)}")
print(f"未来 6 期外推预测值：{np.round(brown_future, 6)}")



plt.figure(figsize=(12,5))
plt.plot(df["time_str"], df["index"], c="black", marker="o", label="实际消费品指数")
plt.plot(df["time_str"], df["MA3"], c="#d62728", linestyle="--", marker="s", label="T=3 移动平均")
plt.plot(df["time_str"], df["MA5"], c="#1f77b4", linestyle="-.", marker="^", label="T=5 移动平均")
plt.plot(df["time_str"], df["MA12"], c="#2ca02c", linestyle=":", marker="D",
label="T=12 移动平均")
plt.title("不同窗口移动平均拟合对比", fontsize=13)
plt.xlabel("时间")
plt.ylabel("指数")
plt.xticks(df["time_str"][::3], rotation=40)
plt.legend()
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()



plt.figure(figsize=(12,5))
plt.plot(df["time_str"], df["index"], c="black", marker="o", label="实际消费品指数")
plt.plot(df["time_str"], df["SES_0.3"], c="#ff7f0e", linestyle="--", label="α=0.3 一次指数平滑")
plt.plot(df["time_str"], df["SES_0.5"], c="#9467bd", linestyle="-.", label="α=0.5 一次指数平滑")
plt.plot(df["time_str"], df["SES_0.7"], c="#8c564b", linestyle=":", label="α=0.7 一次指数平滑")
plt.title("不同 α 一次指数平滑拟合对比", fontsize=13)
plt.xlabel("时间")
plt.ylabel("指数")
plt.xticks(df["time_str"][::3], rotation=40)
plt.legend()
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
```

```
plt.figure(figsize=(12,5))
plt.plot(df["time_str"], df["index"], c="black", marker="o", label="实际消费品指数")
plt.plot(df["time_str"], df["BROWN_1STEP"], c="#c41e3a", linestyle="--", label="布朗二次指数平滑 α=0.3 一步拟合")
future_time = [f"1995.{12+i}" for i in range(1,7)]
plt.plot(future_time, brown_future, c="#c41e3a", linestyle="--", marker="*", label="布朗模型未来 6 期外推预测")
plt.title("布朗单一参数二次指数平滑拟合与外推预测", fontsize=13)
plt.xlabel("时间")
plt.ylabel("指数")
all_ticks = list(df["time_str"][::3]) + future_time
plt.xticks(all_ticks, rotation=40)
plt.legend()
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show()
mask_eval = df["time_str"].between("1994.1","1995.11")
df_eval = df.loc[mask_eval].copy()
mape_full = {
    "T3":calc_mape(df["index"],df["MA3"]),
    "T5":calc_mape(df["index"],df["MA5"]),
    "T12":calc_mape(df["index"],df["MA12"]),
    "a0.3":calc_mape(df["index"],df["SES_0.3"]),
    "a0.5":calc_mape(df["index"],df["SES_0.5"]),
    "a0.7":calc_mape(df["index"],df["SES_0.7"]),
    "brown":calc_mape(df["index"],df["BROWN_1STEP"])
}
mape_eval = {
    "T3":calc_mape(df_eval["index"],df_eval["MA3"]),
    "T5":calc_mape(df_eval["index"],df_eval["MA5"]),
    "T12":calc_mape(df_eval["index"],df_eval["MA12"]),
    "a0.3":calc_mape(df_eval["index"],df_eval["SES_0.3"]),
    "a0.5":calc_mape(df_eval["index"],df_eval["SES_0.5"]),
    "a0.7":calc_mape(df_eval["index"],df_eval["SES_0.7"]),
    "brown":calc_mape(df_eval["index"],df_eval["BROWN_1STEP"])
}
print("\n" + "="*70)
print(f"{'模型':<15}{'全周期 MAPE(%)':<18}{'评估区间 1994.1-1995.11 MAPE(%)'}")
```

```
print("-"*70)
print(f"{'T=3 移动平均':<15}{mape_full['T3']:<18}{mape_eval['T3']}")
print(f"{'T=5 移动平均':<15}{mape_full['T5']:<18}{mape_eval['T5']}")
print(f"{'T=12 移动平均':<15}{mape_full['T12']:<18}{mape_eval['T12']}")
print(f"{'α=0.3 一次平滑':<15}{mape_full['a0.3']:<18}{mape_eval['a0.3']}")
print(f"{'α=0.5 一次平滑':<15}{mape_full['a0.5']:<18}{mape_eval['a0.5']}")
print(f"{'α=0.7 一次平滑':<15}{mape_full['a0.7']:<18}{mape_eval['a0.7']}")
print(f"{'布朗二次 α=0.3':<15}{mape_full['brown']:<18}{mape_eval['brown']}")
print("="*70)
plt.figure(figsize=(10,5))
plt.plot(df_eval["time_str"], df_eval["index"], c="black", marker='o',label="实际消费品指数")
plt.plot(df_eval["time_str"], df_eval["SES_0.3"], c="#ff7f0e", linestyle="--",
label="α=0.3")
plt.plot(df_eval["time_str"], df_eval["SES_0.5"], c="#9467bd", linestyle="-.",
label="α=0.5")
plt.plot(df_eval["time_str"], df_eval["SES_0.7"], c="#8c564b", linestyle=":",
label="α=0.7")
plt.title("一次指数平滑拟合对比",fontsize=13)
plt.xlabel("时间")
plt.ylabel("指数")
plt.xticks(df_eval["time_str"][::2],rotation=45)
plt.legend()
plt.grid(alpha=0.3)
plt.tight_layout()
plt.show(
print("\n===== 完整预测数据表 时间、实际指数、MA3、MA5、MA12、SES0.3、SES0.5、SES0.7、BROWN_1STEP =====")
out_cols = ["time_str", "index", "MA3", "MA5", "MA12", "SES_0.3", "SES_0.5",
"SES_0.7", "BROWN_1STEP"]
print(df[out_cols].to_string(index=False, na_rep="-"))
```