哈　尔　滨　理　工　大　学　理　学　院

专　业　实　验　报　告

课程名称	时间序列分析		总 评 成 绩
实验题目	非平稳时间序列建模与分析		
实 验 者	xxx	班级、学号	统计23-2班 xxxxxxxxxx
时　　间	2026.05.13	地　　点	新主楼C911

报告要求及时、认真、完整的完成。报告的主要内容参考如下：①实验目的；②实验原理；③实验仪器；④实验步骤；⑤数据处理（原始数据附后）；⑥实验结果及误差处理；⑦讨论收获、建议等。

一、实验目的

1.熟练运用时间序列分解方法，将包含趋势项和季节项的数据分解，准确获取趋势、季节和随机成分，深入理解数据的内在结构。

2.掌握 ARIMA 季节模型的原理与构建流程，能够根据数据特点选择合适的模型参数，对序列进行有效的随机性分析，提升数据建模能力。

3.利用已建立的 ARIMA 季节模型，对数据进行 5 期预测，掌握预测方法和结果评估，为实际应用提供可靠的预测数据和决策依据。

二、实验原理

1.ARIMA 模型

具有如下结构的模型称为求和自回归移动平均模型，简记为 $ARIMA(p,d,q)$ 模型：

$$\left\{\begin{array}{l}\Phi(B)\nabla^d x_t=\Theta(B)\varepsilon_t\\ E(\varepsilon_t)=0, Var(\varepsilon_t)=\sigma_\varepsilon^2, E(\varepsilon_t\varepsilon_s)=0, s\neq t\\ E(x_s\varepsilon_t)=0, \forall s<t\end{array}\right\} \tag{1}$$

其中，$\nabla^d=(1-B)^d;\Phi(B)=1-\phi_1B-\cdots-\phi_pB^p$，为平稳可逆 $ARIMA(p,q)$ 模型的自回归系数多项式；$\Theta(B)=1-\theta_1B-\cdots-\theta_qB^q$，为平稳可逆 $ARIMA(p,q)$ 模型的移动平均系数多项式。

特别地，当 d=0 时， $ARIMA(p,d,q)$ 模型实际上就是 $ARMA(p,q)$ 模型；

当 p=0 时， $ARIMA(0,d,q)$ 模型可以简记为 $IMA(d,q)$ 模型；

当 q=0 时， $ARIMA(p,d,0)$ 模型可以简记为 $ARI(p,d)$ 模型；

当 $d=1, p=q=0$ 时， $ARIMA(0,1,0)$ 模型为：

$$\left\{\begin{array}{l} x_t = x_{t-1} + \varepsilon_t \\ E(\varepsilon_t) = 0, Var(\varepsilon_t) = \sigma_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \\ E(x_s \varepsilon_t) = 0, \forall s < t \end{array}\right\} \tag{2}$$

该模型又称为随机游走模型。

2. ARIMA 模型的性质

（1）平稳性

自回归系数多项式的根即特征根的倒数，所以 $ARIMA(p,d,q)$ 模型共有 $p+d$ 个特征根，其中 p 个根在单位圆内，d 个根在单位圆上。因为有 d 个特征根在单位圆上而非单位圆内，所以当 $d \neq 0$ 时，$ARIMA(p,d,q)$ 模型不平稳。

（2）方差齐性

对于 $ARIMA(p,d,q)$ 模型，当 d≠0 时，不仅均值非常数，而且序列方差也非齐性。

3. ARIMA 模型的预测

ARIMA(p,d,q) 模型的一般表示方法为：$\Phi(B)(1-B)^d x_t = \Theta(B)\varepsilon_t$

Ψ_j 的值满足如下的递推公式：

$$\left\{\begin{array}{l} \Psi_1 = \phi_1 - \theta_1 \\ \Psi_2 = \phi_1 \Psi_1 + \phi_2 - \theta_2 \\ \quad \vdots \\ \Psi_j = \phi_1 \Psi_{j-1} + \ldots + \phi_{p+d} \Psi_{j-p-d} - \theta_j \end{array}\right.$$

其中，$\Psi_j = \begin{cases} 0, & j < 0 \\ 1, & j = 0 \end{cases}$，$\theta_j = 0, j > q$

在均方误差最小原则下，1 期预测值为：$\hat{x}_t(l) = \Psi_l \varepsilon_t + \Psi_{l+1} \varepsilon_{t-1} + \Psi_{l+2} \varepsilon_{t-2} + \ldots$

l 期预测误差为：$e_t(l) = \varepsilon_{t+l} + \Psi_1 \varepsilon_{t+l-1} + \ldots + \Psi_{l-1} \varepsilon_{t+1}$

l 期预测误差的方差为：$\mathrm{Var}[e_t(l)] = (1 + \Psi_1^2 + \Psi_2^2 + \ldots + \Psi_{l-1}^2)\sigma_\varepsilon^2$

4. 对于含有趋势项和季节效应的 ARIMA 模型，我们进行因素分解。

因素分解模型：

加法模型：$x_t = S_t + T_t + I_t$

乘法模型：$x_t = T_t \times S_t \times I_t$

5. 简单中心移动平均方法，进行趋势效应的提取

移动平均的计算公式为：

$$M(x_t) = \sum_{i=-k}^{k} \theta_i x_{t-i}, \quad \forall k > 0$$

简单中心移动平均法能够有效的提取低阶趋势，同时该方法能够实现拟合方差最小；简单中心移动平均能够消除季节效应，对于有稳定季节周期的序列进行周期长度的简单移动平均可以消除季节效应。

6. 季节效应提取

加法模型中季节指数的构造；

乘法模型中季节指数的构造；

X_{11} 季节调节模型

7. 建立相应的预测模型

e.g. ARIMA 加法模型、ARIMA 乘法模型

三、实验仪器

R4.4.3 以及 RStudio

四、实验内容和步骤

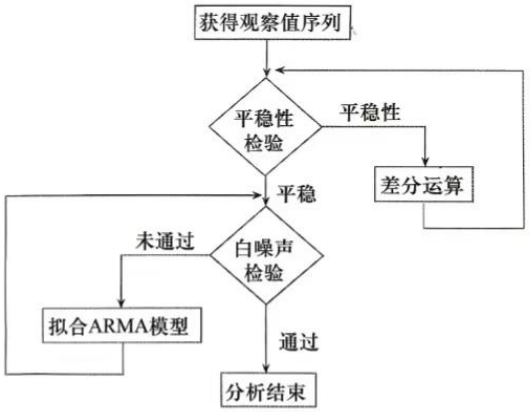


图 1 ARIMA建模过程

1. 绘制原始序列的时序图，观察数据中存在的长期趋势和季节波动特征；
2. 对于月季数据采用12阶中心化移动平均方法，计算并提取序列的趋势项成分；
3. 在原序列图中叠加趋势线，直观对比趋势项与原始序列的变化关系，从原始序列中减去趋势项，得到包含季节效应和随机波动的混合序列；
4. 按月份分组计算混合序列的平均值，获得各月的初步季节指数，对各月平均值进行中心化调整，使季节指数之和为零，得到加法季节指数；
5. 将季节指数按周期重复扩展，生成与原始序列等长的季节项序列，从原序列中同时减去趋势项和季节项，提取出随机项（残差）序列；
6. 绘制展示原序列、趋势项、季节项和随机项的加法模型的四合一分解图，绘制季节指数的条形图，比较不同月份的季节效应对屠宰量的影响；
7. 采用乘法模型重复上述分解过程，将季节指数调整为均值归一化形式，绘制乘法模型的四合一分解图，作为加法模型的对比参照；
8. 对原始序列做一阶差分，再对差分结果做12步季节差分，以消除趋势和季节效应，使用ADF检验验证差分后序列的平稳性，检验p值显示序列是否平稳；
9. 计算Ljung-Box统计量，检验差分后序列是否为纯随机白噪声，绘制原序列的自相关函数图和偏自相关函数图，识别非平稳特征，绘制差分后序列的ACF图和PACF图，辅助判断模型的阶数；
10. 调用auto.arima函数，以AICc准则自动搜索最优SARIMA模型，输出模型参数的估计值及其标准误，记录模型的拟合优度指标，提取模型残差序列，绘制时序图、ACF图、直方图和QQ图进行诊断；
11. 使用拟合的SARIMA模型对未来5个月的数据进行预测，输出预测的点估计值以及80%和95%置信区间的上下限并绘制预测图，展示历史拟合值与未来预测趋势及置信带范围，整理预测结果表格，列出各预测期的时间、点预测值和区间估计值。

五、数据处理

本实验所应用的数据为《时间序列分析——基于R》(第二版)课后习题6.8的数据，该数据为188个连续生产记录原始数据具体如下表:

表 1 原始数据表

76378,71947,33873,96428,105084,95741,110647,100331,94133,103055,90595,101457,76889,81291,91643,96228,102736,100264,103491,97027,95240,91680,101259,109564,76892,85773,95210,93771,98202,97906,100306,94089,102680,77919,93561,117062,81225,88357,106175,91922,104114,109959,97880,105386,96479,97580,109490,110191,90974,98981,107188,94177,115097,113696,114532,120110,93607,110925,103312,120184,103069,103351,111331,106161,111590,99447,101987,85333,86970,100561,89543,89265,82719,79498,74846,73819,77029,78446,86978,75878,69571,75722,64182,77357,63292,59380,78332,72381,55971,69750,85472,70133,79125,85805,81778,86852,69069,79556,88174,66698,72258,73445,76131,86082,75443,73969,78139,78646,66269,73776,80034,70694,81823,75640,75540,82229,75345,77034,78589,79769,75982,78074,77588,84100,97966,89051,93503,84747,74531,91900,81635,89797,81022,78265,77271,85043,95418,79568,103283,95770,91297,101244,114525,101139,93866,95171,100183,103926,102643,108387,97077,90901,90336,88732,83759,99267,73292,78943,94399,92937,90130,91055,106062,103560,104075,101783,93791,102313,82413,83534,109011,96499,102430,103002,91815,99067,110067,101599,97646,104930,88905,89936,106723,84307,114896,106749,87892,100506

六、数据结果分析

首先，我们会画出原始数据的时序图，序列是否来观察存在线性或非线性的趋势项。

```
> plot(y, main = "1980-1995 生猪屠宰数量时序图",xlab = "年份", ylab = "屠宰数量（头）", col = "blue", lwd = 2)> grid(col = "lightgray", lty = 3)
```

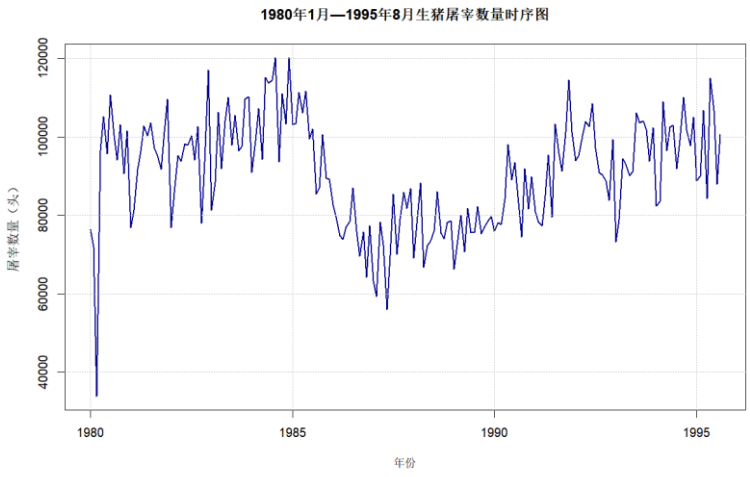


图 2 原始数据时序图

由图可知序列从1980年的约7万头波动上升至1995年的约10万头，每年冬季出现高峰、春季回落。该序列同时存在长期增长趋势和年度季节波动，属于非平稳时间序列，适合采用确定性分解或季节ARIMA模型进行后续分析。

由于原始数据是以月为单位的数据，因此我们采用12阶中心化移动平均方法来提取趋势项，具体代码如下：

```
> n <- 12> weights <- c(0.5, rep(1, n-1), 0.5) / n> trend <- filter(y, filter = weights, method = "convolution", sides = 2)
> plot(y, main = "原序列与 12 阶移动平均趋势",xlab = "年份", ylab = "数量", col = "blue", lwd = 1.5)
> lines(trend, col = "red", lwd = 2.5)> legend("topleft", legend = c("原序列", "趋势"),
  col = c("blue", "red"), lwd = c(1.5, 2.5), bty = "n")
> grid(col = "lightgray", lty = 3)
```

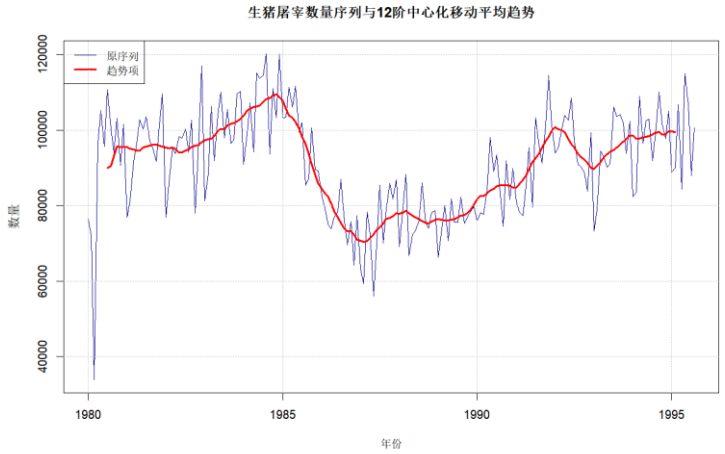


图 3 生猪屠宰数量序列12阶中心化移动平均趋势

上图中的红色线为趋势项序列，曲线平滑，两端有少量缺失值，消除了随机波动。叠加图中红色趋势线穿过蓝色原始序列的中心。数据呈现规则的年度周期，趋势线较好地拟合了序列的长期走向。剔除趋势后的序列仍显示明显季节效应，说明季节成分显著由此，我们可以知道2阶中心化移动平均有效分离了长期趋势，为加法模型分解提供了可靠的趋势分量。

接下来，我们按月平均法计算加法季节指数。通过计算我们可以得到下表：

```
> monthly_avg <- tapply(season_random, cycle(season_random), mean, na.rm = TRUE)
> seasonal_add <- monthly_avg - mean(monthly_avg)
```

表 2 月季节指数

月份	数值
1 月	-10602.1947
2 月	-7338.9391
3 月	1882.5244
4 月	-2662.6363
5 月	2967.2119
6 月	1665.1047
7 月	5844.1164
8 月	2155.2831
9 月	-1546.6475
10 月	991.9275
11 月	-181.9252
12 月	6826.1748

通过上表，可知12月的季节指数为6826.17头，在所有月份中最高；7月为5844.12头，排在第二位。这说明冬天和夏天的屠宰量通常超过全年平均水平。1月和2月的季节指数为负，分别是-10602.19和-7338.94，绝对值较大，屠宰量相对偏低。3月的季节指数为1882.52，是正数，这个结果与一般印象中春季屠宰量偏低的说法不一致，但该数据如实反映了当地的屠宰规律。

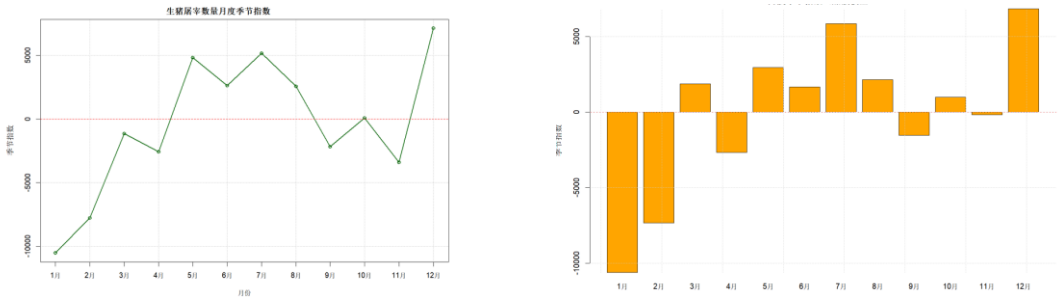


图 4 生猪屠宰数量月度季节指数

接下来，我们来绘制季节项序列与随机项序列，我们可以观察到残差序列围绕零线随机波动，无明显趋势或周期性。由此，我们成功的应用加法模型将原始序列成功分解为三个独立分量。残差呈现随机性，表明分解合理，趋势和季节项解释了大部分变异。

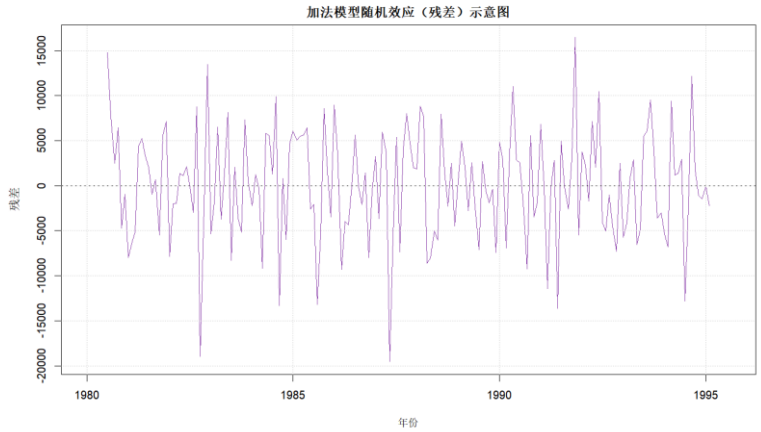


图 5 随机项示意图

接下来，我们绘制出加法模型四合一分解图，该图直观展示了原序列、趋势、季节、残差的形态。条形图显示12月季节指数最高，3月最低。季节效应以一年为周期，12月和7月出现两个高峰，其中12月最强。残差波动幅度较小，说明趋势和季节项解释了数据的主要变化。

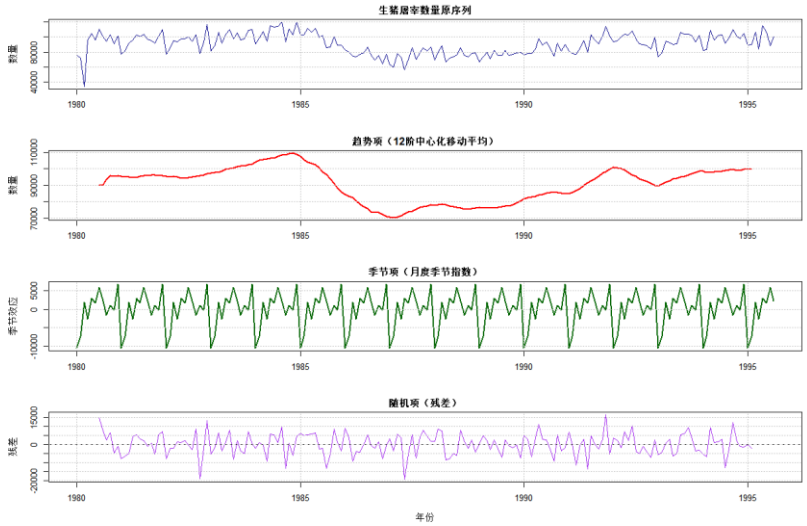


图 6 加法模型因数分解

然后，我们进行乘法模型分解来与加法模型进行对比分析，通过下图可知乘法季节指数均值为1，12月指数约1.15，3月约0.90。随机项围绕1波动，幅度与加法模型残差类似。乘法模型同样能够有效分解序列。由于季节波动幅度未随趋势明显增大，加法模型更为简洁，后续随机性分析采用加法分解的残差作为参考。

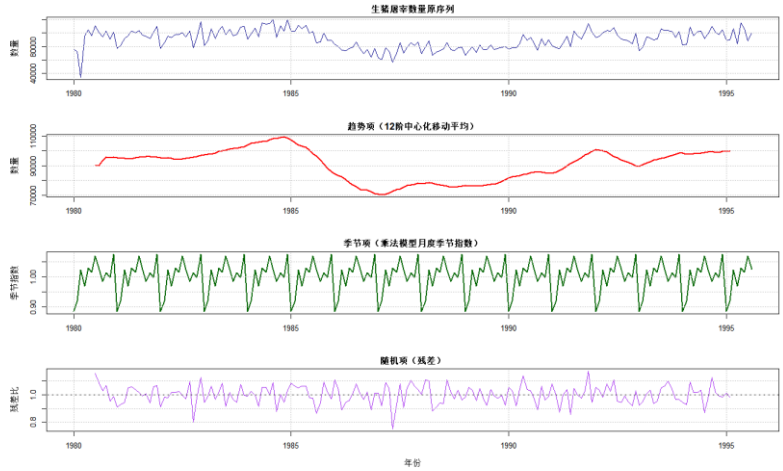


图 7 乘法模型因数分解

我们对经过一阶差分后再做12步季节差分得到的序列进行ADF检验，来判断差分后的序列是否具有平稳性。

```
> adf.test(dy12, alternative = "stationary")

        Augmented Dickey-Fuller Test

data:  dy12
Dickey-Fuller = -6.5843, Lag order = 5,
p-value = 0.01
alternative hypothesis: stationary
```

通过检验结果我们可以发现，原始生猪屠宰序列同时包含上升趋势和年度周期波动，本身不平稳。通过一阶差分可以消除线性趋势，再通过12步季节差分可以移除周期为12的季节性成分。ADF检验针对的是差分处理后的dy12，其p值小于0.01说明该序列已平稳。这一结果满足后续ARIMA建模对平稳性的基本要求，表明可以在此基础上进行模型定阶与参数估计。

然后，我们进行白噪声检验，并绘制差分前后的ACF和PACF图。

通过下图我们可以知道，LB白噪声检验滞后6阶的Q统计量为55.307，对应的p值为4.019e-10；滞后12阶的Q统计量为78.048，对应的p值为9.712e-12。两个检验的p值均远小于0.05的显著性水平。

```
> Box.test(dy12, lag = 6, type = "Ljung-Box")

        Box-Ljung test

data:  dy12
X-squared = 55.307, df = 6, p-value =
4.019e-10
```

```
> Box.test(dy12, lag = 12, type = "Ljung-Box")

        Box-Ljung test

data:  dy12
X-squared = 78.048, df = 12, p-value =
9.712e-12
```

通过下图，我们可以看到原序列的ACF图呈现缓慢衰减的趋势，各阶自相关系数均为正值且衰减速度非常慢，在滞后24阶时仍明显超过置信边界。PACF图在滞后1阶处有一个很高的峰值，随后迅速降低，但滞后2阶及之后仍有部分数值超过置信区间。ACF的缓慢衰减是典型的非平稳序列特征，表明序列存在长期的上升趋势。PACF在滞后1阶处的显著峰值提示序列可能具有自回归结构，但整体图形并不符合平稳ARMA模型应有的截尾或拖尾形态。这一结果进一步证实原序列不平稳，需要进行差分处理。

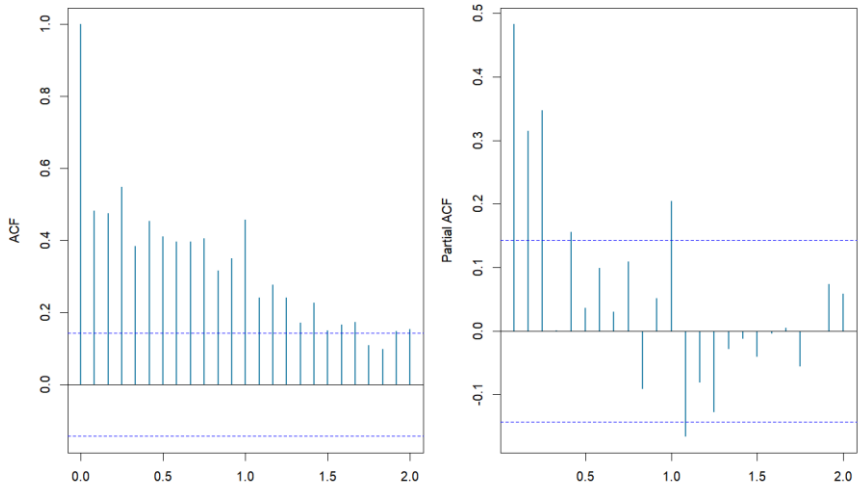


图 8 差分前的ACF和PACF图

经过一阶差分和12步季节差分后，ACF图显示自相关系数在滞后1阶处为负值且显著，在滞后12阶处有一个明显的正值峰值，之后迅速衰减进入置信区间。PACF图在滞后1阶和滞后12阶处出现显著峰值，随后快速截尾。与差分前相比，差分后序列的ACF不再缓慢衰减，而是在短期滞后和季节滞后处呈现有限的相关性，表明趋势已被有效消除。ACF在滞后12阶处的突出表现提示季节相关性存在，PACF在滞后12阶处的截尾则暗示季节部分可能采用自回归结构。这一结果为后续使用SARIMA模型提供了依据。同时，Ljung-Box检验表明差分后序列仍存在显著的自相关关系，确认其不是白噪声，值得继续建模。

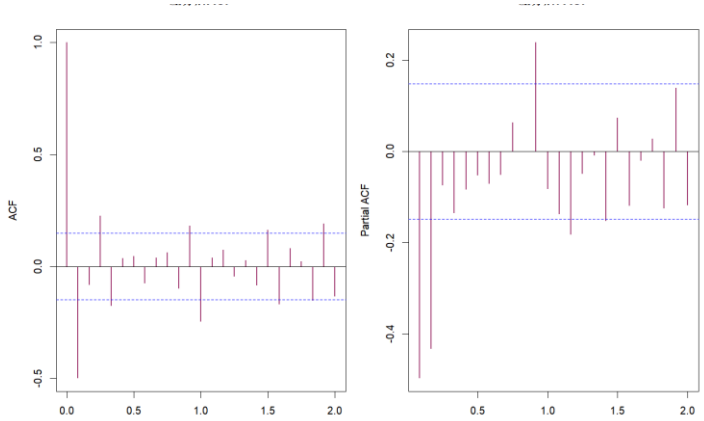


图 9 差分后的ACF和PACF图

接下来，我们应用R语言自动为SARIMA模型进行定阶，通过AICc准则自动搜索，最优模型为SARIMA(2,1,0)(2,0,0)[12]。模型各参数估计值及标准误如下：

```
> # 自动SARIMA建模
> fit <- auto.arima(y, seasonal = TRUE, stepwise = FALSE, approximation = FALSE)
> summary(fit)
Series: y
ARIMA(2,1,0)(2,0,0)[12]

Coefficients:
          ar1      ar2    sar1    sar2
      -0.6538  -0.4952  0.3886  0.1744
s.e.   0.0666   0.0703  0.0812  0.0878

sigma^2 = 84366977:  log likelihood = -1972.03
AIC=3954.06   AICc=3954.39   BIC=3970.21

Training set error measures:
                    ME     RMSE      MAE
Training set 55.55903 9062.184 6916.883
                    MPE     MAPE      MASE
Training set -0.776272 7.97301 0.6921111
                   ACF1
Training set 0.0309038
```

表 3 模型检验表

参数	估计值	标准误	t 值
ar1	-0.6538	0.0666	-9.82
ar2	-0.4952	0.0703	-7.04
sar1	0.3886	0.0812	4.79
sar2	0.1744	0.0878	1.99

由上表可知SARIMA(2,1,0)(2,0,0)[12]模型拟合优度指标，AIC = 3954.06，AICc = 3954.39，BIC = 3970.21。同时该模型的残差时序图在零线上下随机波动，无明显趋势或周期性；残差ACF图中各阶自相关系数基本落在95%置信区间内；残差直方图呈现中间高、两边低的钟形分布；QQ图中的点大致沿对角线分布。

计算各参数的t统计量可知，ar1、ar2、sar1的绝对值均大于2，对应的p值小于0.05，参数显著不为零。sar2的t统计量约为1.99，接近临界值，仍在常规显著性水平下可视为显著。所有参数均保留在模型中，未出现明显的不显著项。

由下图可知，残差围绕零线上下波动，无系统性的上升或下降趋势，说明趋势和季节信息已被充分提取；绝大多数滞后的自相关系数落在蓝色虚线内，仅有几个点不在，我们可以认为可以认为残差不存在显著自相关，即残差接近白噪声；残差直方图中分布形态与正态分布曲线相近，无明显偏斜或异常峰值，表明随机项大致服从正态分布，这为区间预测的可靠性提供了基础；样本分位数与理论正

态分位数基本落在参考线附近，尾部略有偏离但整体可以接受，未发现严重的厚尾或偏态问题。

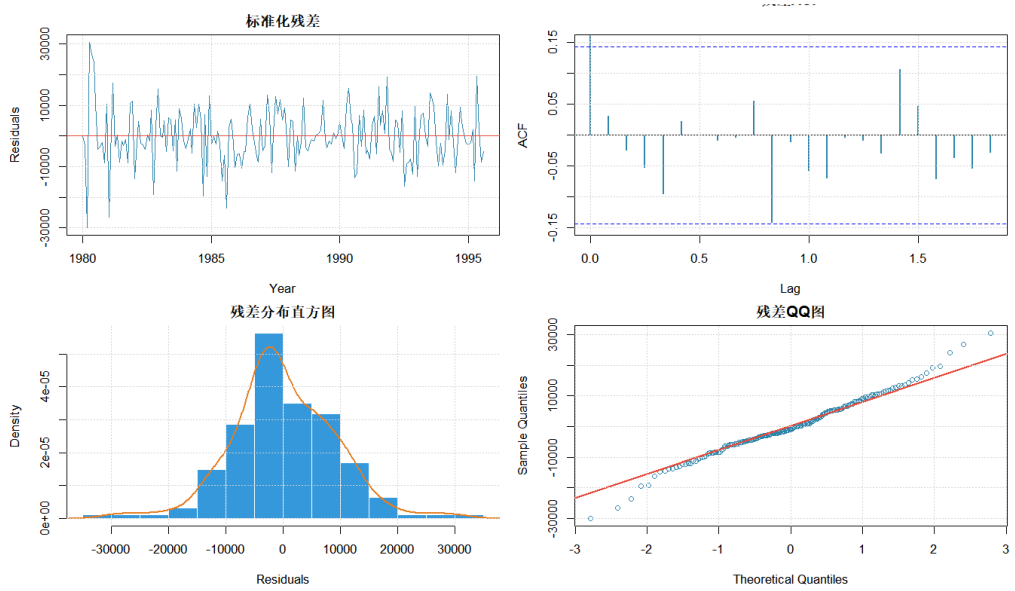


图 10 残差分析图

最后，我们给出该模型预测出的未来5期的生猪屠宰数量。具体代码如下：

```
> # 预测未来5期
> pred <- forecast(fit, h = 5)
> pred
         Point Forecast    Lo 80    Hi 80
Sep 1995      106661.12 94889.87 118432.4
Oct 1995       96733.38 84276.51 109190.3
Nov 1995       96995.06 84114.13 109876.0
Dec 1995      102313.76 87352.74 117274.8
Jan 1996       90381.93 74551.85 106212.0
            Lo 95    Hi 95
Sep 1995 88658.55 124663.7
Oct 1995 77682.24 115784.5
Nov 1995 77295.38 116694.7
Dec 1995 79432.86 125194.7
Jan 1996 66171.91 114591.9
```

我们得到相应的预测结果如下表：

表 4 未来五期的生猪屠宰数量

时间	预测值	95% 置信区间下限	95% 置信区间上限
1995 年 9 月	106661	88659	124664
1995 年 10 月	96733	77682	115785
1995 年 11 月	96995	77295	116695
1995 年 12 月	102314	79433	125195
1996 年 1 月	90382	66172	114592

预测图显示历史拟合值紧密跟随原始序列，未来预测曲线延续了上升趋势和季节波动模式，置信区间随预测步长适当扩大。预测结果捕捉了年末屠宰量上升、

年初回落的季节特征。80%和95%置信区间宽度合理，反映了短期预测的不确定性。该模型可用于辅助生猪屠宰相关的生产计划制定。

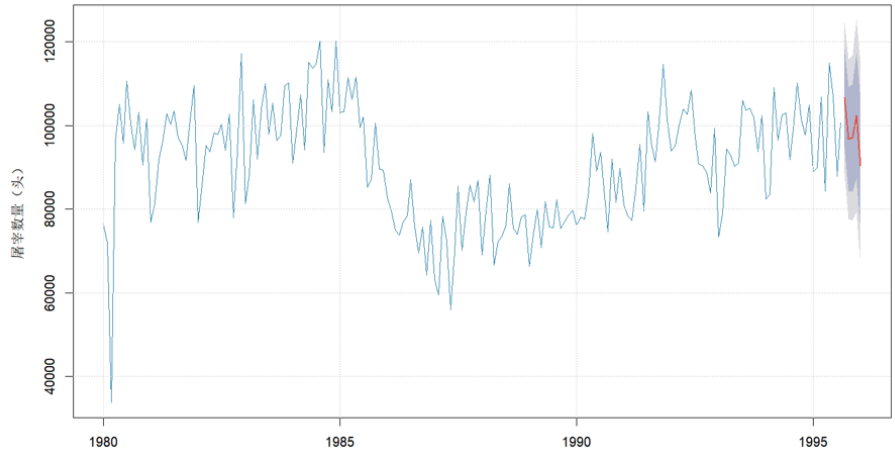


图 11 未来五期的生猪屠宰数量预测图

七、实验收获

本次时间序列分析实验以1980年至1995年的生猪屠宰月度数据为研究对象，重点完成了确定性因素分解和SARIMA建模两项任务。通过实际操作，我较为系统地掌握了从非平稳序列中提取趋势、季节和随机成分的方法，以及基于差分和自相关结构的模型识别技巧。

在确定性分解部分，我采用12阶中心化移动平均提取了长期趋势，发现屠宰量在15年间呈现波动上升的态势。利用按月平均法计算加法季节指数后，我观察到12月和7月的季节指数较高，1月和2月则明显偏低，这一结果反映了该城市生猪屠宰的季节性特征。为了对比，我也尝试了乘法模型分解，两种模型给出的季节模式相近，但从残差波动幅度来看，加法模型在本数据中更为简洁适用。

在随机性分析部分，我首先对原始序列做了一阶差分和12步季节差分，然后使用ADF检验验证差分后序列的平稳性，检验结果支持平稳假设。通过观察差分后序列的自相关函数图和偏自相关函数图，我注意到ACF在滞后12阶处有显著峰值，PACF在同样位置截尾，这为季节自回归项的选择提供了依据。借助auto.arima函数，模型自动选定了SARIMA(2,1,0)(2,0,0)[12]结构。参数估计值均通过显著性检验，残差诊断中的时序图、ACF图、直方图和QQ图均显示残差接近白噪声，说明模型提取了原始序列中的主要信息。

利用该模型对未来5个月的屠宰量进行预测后，我获得了各期的点预测值及80%、95%的置信区间。预测结果显示冬季屠宰量依然偏高，但置信区间随预测步长有所扩大，说明长期预测的不确定性会增加。通过本次实验，我从数据预处理、平稳化处理、模型识别与诊断到最终预测，建立起一套较为完整的时间序列分析流程。这些经验有助于我今后处理类似的经济或生产数据，也让我认识到在模型选择时需要结合具体数据特征进行判断，而不应完全依赖自动建模的结果。

指导教师：xxx

时间：2026年5月14日

实验代码

```
#数据导入
data <- c(
      76378,71947,33873,96428,105084,95741,110647,100331,94133,103055,90595,101457,
      76889,81291,91643,96228,102736,100264,103491,97027,95240,91680,101259,109564,
      76892,85773,95210,93771,98202,97906,100306,94089,102680,77919,93561,117062,
      81225,88357,106175,91922,104114,109959,97880,105386,96479,97580,109490,110191,
      90974,98981,107188,94177,115097,113696,114532,120110,93607,110925,103312,120184,
      103069,103351,111331,106161,111590,99447,101987,85333,86970,100561,89543,89265,
      82719,79498,74846,73819,77029,78446,86978,75878,69571,75722,64182,77357,
      63292,59380,78332,72381,55971,69750,85472,70133,79125,85805,81778,86852,
      69069,79556,88174,66698,72258,73445,76131,86082,75443,73969,78139,78646,
      66269,73776,80034,70694,81823,75640,75540,82229,75345,77034,78589,79769,
      75982,78074,77588,84100,97966,89051,93503,84747,74531,91900,81635,89797,
      81022,78265,77271,85043,95418,79568,103283,95770,91297,101244,114525,101139,
      93866,95171,100183,103926,102643,108387,97077,90901,90336,88732,83759,99267,
      73292,78943,94399,92937,90130,91055,106062,103560,104075,101783,93791,102313,
      82413,83534,109011,96499,102430,103002,91815,99067,110067,101599,97646,104930,
      88905,89936,106723,84307,114896,106749,87892,100506
)
y <- ts(data, start = c(1980, 1), frequency = 12)

library(forecast)

# 时序图
plot(y, main = "1980-1995 生猪屠宰数量时序图",
     xlab = "年份", ylab = "屠宰数量（头）", col = "blue", lwd = 2)
grid(col = "lightgray", lty = 3)

# 12阶中心化移动平均提取趋势
n <- 12
weights <- c(0.5, rep(1, n-1), 0.5) / n
trend <- filter(y, filter = weights, method = "convolution", sides = 2)

# 原序列与趋势线
plot(y, main = "原序列与12阶移动平均趋势",
     xlab = "年份", ylab = "数量", col = "blue", lwd = 1.5)
lines(trend, col = "red", lwd = 2.5)
legend("topleft", legend = c("原序列", "趋势"),
       col = c("blue", "red"), lwd = c(1.5, 2.5), bty = "n")
grid(col = "lightgray", lty = 3)

# 加法模型分解
season_random <- y - trend
monthly_avg <- tapply(season_random, cycle(season_random), mean, na.rm = TRUE)
seasonal_add <- monthly_avg - mean(monthly_avg)
season_add <- ts(rep(seasonal_add, length.out = length(y)),
                 start = start(y), frequency = 12)
random_add <- y - trend - season_add

# 随机效应图
plot(random_add, main = "加法模型随机效应",
     xlab = "年份", ylab = "残差", col = "purple")
abline(h = 0, lty = 2)
```

```
grid(col = "lightgray", lty = 3)

# 加法模型四合一图
par(mfrow = c(4, 1), mar = c(3, 4, 2, 1))
plot(y, main = "原序列 (Y)", xlab = "", col = "blue")
grid(col = "lightgray", lty = 3)
plot(trend, main = "趋势项 (T)", xlab = "", col = "red", lwd = 2)
grid(col = "lightgray", lty = 3)
plot(season_add, main = "季节项 (S)", xlab = "", col = "orange", lwd = 2)
abline(h = 0, lty = 2)
grid(col = "lightgray", lty = 3)
plot(random_add, main = "随机项 (I)", xlab = "年份", col = "purple")
abline(h = 0, lty = 2)
grid(col = "lightgray", lty = 3)
par(mfrow = c(1, 1))

# 季节指数条形图
barplot(seasonal_add[1:12], names.arg = paste0(1:12, "月"),
        main = "月度季节指数（加法模型）",
        xlab = "月份", ylab = "季节指数", col = "orange")
abline(h = 0, col = "red", lty = 2)
grid(col = "lightgray", lty = 3)

# 乘法模型分解（备选）
trend_multi <- filter(y, filter = weights, method = "convolution", sides = 2)
season_random_multi <- y / trend_multi
monthly_avg_multi <- tapply(season_random_multi, cycle(season_random_multi), mean, na.rm =
TRUE)
seasonal_multi <- monthly_avg_multi / mean(monthly_avg_multi)
season_multi <- ts(rep(seasonal_multi, length.out = length(y)),
                   start = start(y), frequency = 12)
random_multi <- y / trend_multi / season_multi

par(mfrow = c(4, 1), mar = c(3, 4, 2, 1))
plot(y, main = "原序列 (Y)", xlab = "", col = "blue")
grid(col = "lightgray", lty = 3)
plot(trend_multi, main = "趋势项 (T)", xlab = "", col = "red", lwd = 2)
grid(col = "lightgray", lty = 3)
plot(season_multi, main = "季节项 (S)", xlab = "", col = "orange", lwd = 2)
abline(h = 1, lty = 2)
grid(col = "lightgray", lty = 3)
plot(random_multi, main = "随机项 (I)", xlab = "年份", col = "purple")
abline(h = 1, lty = 2)
grid(col = "lightgray", lty = 3)
par(mfrow = c(1, 1))

# 差分与平稳性检验
dy <- diff(y)
dy12 <- diff(dy, 12)

# ADF检验
library(tseries)
adf.test(dy12, alternative = "stationary")

# Ljung-Box白噪声检验
```

```
Box.test(dy12, lag = 6, type = "Ljung-Box")
Box.test(dy12, lag = 12, type = "Ljung-Box")

# 原序列ACF/PACF
par(mfrow = c(1, 2))
acf(y, lag.max = 24, main = "原序列ACF")
pacf(y, lag.max = 24, main = "原序列PACF")
par(mfrow = c(1, 1))

# 差分后ACF/PACF
par(mfrow = c(1, 2))
acf(dy12, lag.max = 24, main = "差分后ACF")
pacf(dy12, lag.max = 24, main = "差分后PACF")
par(mfrow = c(1, 1))

# 自动SARIMA建模
fit <- auto.arima(y, seasonal = TRUE, stepwise = FALSE, approximation = FALSE)
summary(fit)

# 残差诊断
res <- residuals(fit)
par(mfrow = c(2, 2))
plot(res, main = "残差时序图", ylab = "Residuals")
abline(h = 0, lty = 2)
acf(res, main = "残差ACF")
hist(res, main = "残差直方图", col = "lightblue")
qqnorm(res); qqline(res, col = "red")
par(mfrow = c(1, 1))

# 预测未来5期
pred <- forecast(fit, h = 5)
pred

# 预测图
plot(pred, main = "未来5期预测", xlab = "年份", ylab = "屠宰数量")
grid(col = "lightgray", lty = 3)

# 预测表格
pred_df <- data.frame(
      时间  = time(pred$mean),
      预测值  = round(pred$mean),
      Lo80 = round(pred$lower[, 1]),
      Hi80 = round(pred$upper[, 1]),
      Lo95 = round(pred$lower[, 2]),
      Hi95 = round(pred$upper[, 2])
)
print(pred_df)
```